

Matriz de Extracción de Artículos Científicos

Información general del estudiante (ejemplo)

- **Nombre del estudiante:** Cael Alejandro Soto Castillo
- **Técnica de IA:** XGBoost
- **Pregunta de investigación:** ¿Qué ventajas ofrece XGBoost en problemas de clasificación?
- **Cadena de búsqueda:**

Showing 1-25 of 70,981 results for
("All Metadata":"XGBoost") OR ("All Metadata":Extreme Gradient Boosting) AND ("All Metadata":classification) AND ("All Metadata":performance) OR ("All Metadata":evaluation) OR ("All Metadata":accuracy) ✕

Matriz de extracción (ejemplo con 5 artículos)

#	Referencia (IEEE)	Año	Base de datos	Técnica IA	Problema abordado	Objetivo del artículo	Metodología	Dataset / Contexto	Resultados principales	Limitaciones	Aporte para la PI
1	H. A. Alamri and V. Thayananthan, "Bandwidth Control Mechanism and Extreme Gradient Boosting Algorithm for Protecting Software-Defined Networks Against DDoS Attacks," IEEE Access, vol. 8, 2020.	2020	IEEE Xplore	Extreme Gradient Boosting (XGBoost)	Ataques DDoS en redes SDN	Desarrollar un marco de seguridad híbrido para detectar y mitigar DDoS	Clasificación de tráfico mediante XGBoost combinada con una política de control de ancho de banda	Dataset CICDDoS2019 (escenarios de reflexión y explotación)	Precisión (Accurac y) del 99.1% y F1-Score del 99.2% en la detección de ataques	El rendimiento puede degradarse si el controlador SDN se sobrecarga antes de la mitigación	Provee un modelo de defensa proactiva que no solo detecta, sino que gestiona recursos de red
2	S. Kim, "A Lightweight Intelligent Network Intrusion Detection System for Industrial IoT Using One-Dimensional Convolutional Neural Network," IEEE Access, vol. 11, pp. 118431-118445, 2023.	2023	IEEE Xplore	1D-CNN (Red Neuronal Convolutional 1D)	Intrusiones y ataques en redes de IoT Industrial (IIoT)	Desarrollar un sistema de detección de intrusiones (NIDS) ligero y eficiente	Uso de redes convolucionales 1D para extraer características de tráfico sin alta carga computacional	Dataset Edge-IIoTset y UNSW-NB15	Precisión del 99.42% y 99.16% con un tiempo de inferencia extremadamente bajo	La eficacia depende de la calidad del preprocesamiento de los datos de red	Demuestra la viabilidad de usar aprendizaje profundo en dispositivos con recursos limitados
3	M. S. Uddin, J. B. Al-Siddiki and J. S. S. Shovon, "Gradient Boosting for Predicting the	2023	IEEE Xplore	XGBoost y LightGBM (LGBM) Predicción de	Predicción de convulsiones epilépticas median	Comparar el rendimiento de modelos de Boosting para predecir	Aplicación de ingeniería de características sobre	UCI Machine Learning Repository	XGBoost logró una precisión del 97.43% y LGBM del	Alta dependencia del preprocesamiento de señales ruidosas de	Valida el uso de XGBoost para análisis de

	Relation Between Bio-Medical Signals and Seizures Using LGBM and XGBoost," 5th International Conference on Sustainable Technologies for Industry 5.0 (STI), Dhaka, Bangladesh, 2023.			convulsiones epilépticas mediante señales de EEG	señales de EEG	ataques epilépticos	señales EEG y entrenamiento de modelos de Boosting	(Epileptic Seizure Recognition Dataset)	97.13%	EEG	series temporales y eventos críticos
4	J. Li, J. Cheng, J. Zhou and L. Chen, "Classification Task-Driven Hyperspectral Band Selection via Interpretability From XGBoost," IEEE Geoscience and Remote Sensing Letters, vol. 19, 2022.	2022	IEEE Xplore	XGBoost (Interpretabilidad / Importancia de características)	Selección de bandas en imágenes hiperespectrales (alta dimensionalidad)	Proponer un método de selección de bandas basado en la importancia que XGBoost asigna a los datos	Utiliza los puntajes de importancia de XGBoost para identificar las bandas más relevantes y reducir la redundancia	Dataset Indian Pines, Pavia University y Salinas Mejora la precisión de clasificación reduciendo drásticamente la cantidad de datos procesados	Mejora la precisión de clasificación reduciendo drásticamente la cantidad de datos procesados	La selección depende fuertemente de la calidad del entrenamiento inicial del modelo	Provee una técnica para reducir la complejidad de los datos (reducción de dimensionalidad)
5	Z. Wu, S. Cui and H. Yuan, "Robust Classification of UWB NLOS/LOS Using Combined FCE and XGBoost Algorithms," IEEE Communications Letters, vol. 26, no. 10, pp. 2375-2379, 2022.	2022	IEEE Xplore	FCE (Fuzzy Cluster Ensemble) y XGBoost	Clasificación de señales NLOS (sin línea de visión) en Ultra-Wideband (UWB)	Mejorar la precisión del posicionamiento en interiores clasificando tipos de señales	Combina lógica difusa (FCE) para pre-clasificar datos y XGBoost para la clasificación final robusta	Dataset de señales UWB recolectado en entornos reales de oficina y laboratorios	Precisión de clasificación del 93.42%, superando a métodos tradicionales de ML	Mayor complejidad estructural al combinar algoritmos diferentes	Ofrece un enfoque de "ensamble" para mejorar la fiabilidad en entornos con mucho ruido

Síntesis del ejemplo (modelo que el estudiante debe replicar)

El algoritmo XGBoost (Extreme Gradient Boosting) se ha consolidado como una de las técnicas de aprendizaje supervisado más eficientes, destacándose por su capacidad de modelar relaciones no lineales complejas mediante el uso de conjuntos de árboles de decisión. A diferencia de los métodos tradicionales, esta implementación avanzada integra técnicas de regularización para

mitigar el sobreajuste y optimizar el uso de recursos computacionales a través del procesamiento paralelo. A través de las fuentes analizadas, se evidencia que la versatilidad de XGBoost permite su aplicación en una amplia gama de campos críticos:

- **Seguridad de Redes y Comunicaciones:** Es fundamental para la detección precisa de ataques DDoS en entornos SDN y para la identificación de señales en sistemas de posicionamiento inalámbrico, donde la velocidad de respuesta y la baja tasa de errores son vitales.
- **Análisis Biomédico:** Ha demostrado ser una herramienta superior en la clasificación de señales complejas, como los datos de EEG para la predicción de convulsiones, superando en precisión a modelos clásicos.
- **Interpretabilidad y Optimización de Datos:** Su capacidad para asignar puntajes de importancia a las características facilita la selección de datos críticos, permitiendo reducir la dimensionalidad en tareas complejas como el análisis de imágenes hiperespectrales.
- **Robustez y Escalabilidad:** Los estudios confirman que el algoritmo mantiene una estabilidad notable incluso en escenarios con datos ruidosos o interferencias elevadas, lo que permite su integración en arquitecturas modernas de microservicios e IoT.

En conclusión, XGBoost representa un estándar de excelencia cuando se requiere un equilibrio superior entre precisión predictiva y eficiencia computacional, demostrando ser una solución robusta para desafíos técnicos contemporáneos.

Respuesta a la pregunta de investigación

¿Qué ventajas ofrece XGBoost en problemas de clasificación?

El algoritmo XGBoost (Extreme Gradient Boosting) se distingue en tareas de clasificación por su excepcional equilibrio entre precisión predictiva y eficiencia computacional, consolidándose como un estándar superior frente a modelos tradicionales como SVM o Regresión Logística. Su principal fortaleza reside en una implementación avanzada del aprendizaje aditivo, que combina secuencialmente árboles de decisión para corregir errores previos, logrando métricas de precisión y F1-score que rozan el 99.9% en escenarios críticos como la seguridad de redes. A diferencia de otros métodos de aumento de gradiente, XGBoost integra regularización L1 y L2 directamente en su función de costo, lo que mitiga el sobreajuste (overfitting) y garantiza una generalización robusta incluso ante datos ruidosos, desequilibrados o con interferencias.

A nivel de infraestructura, su arquitectura de procesamiento en paralelo optimiza el uso de recursos del sistema, permitiendo tiempos de entrenamiento y respuesta en milisegundos, lo cual es vital para aplicaciones en tiempo real y dispositivos con hardware limitado donde modelos de Deep Learning resultarían demasiado pesados. Asimismo, el algoritmo aporta un alto grado de interpretabilidad mediante la extracción de la importancia de las características (feature importance), facilitando la comprensión de la toma de decisiones y la selección automática de las variables más relevantes. Finalmente, su versatilidad para trabajar eficazmente con conjuntos de datos pequeños y su capacidad de aprendizaje dual bajo marcos unificados lo posicionan como una herramienta integral, capaz de adaptarse a diversos entornos de investigación y producción con una estabilidad notable.