

Fundamentos de Inteligencia Artificial Clásica: Técnicas, Métodos y Aplicaciones Antes de la IA Generativa

Luis Chamba-Eras

Editor

2026

Índice general

I	Introducción y Fundamentos	1
II	Aprendizaje Estadístico y Modelos de Clasificación	2
1.	Ventajas Arquitectónicas y Algorítmicas de XGBoost en Problemas Comple-	3
	jos de Clasificación	
1.1.	Introducción	3
1.2.	Fundamentos Teóricos	4
1.3.	Metodología y Análisis de la Literatura	4
1.4.	Conclusiones	4

Parte I

Introducción y Fundamentos

Parte II

Aprendizaje Estadístico y Modelos de Clasificación

Capítulo 1

Ventajas Arquitectónicas y Algorítmicas de XGBoost en Problemas Complejos de Clasificación

Autor: Cael Alejandro Soto Castillo (cael.soto@unl.edu.ec)
Técnica asignada: XGBoost

1.1. Introducción

Contexto general del problema

En el marco de los **Sistemas Inteligentes y el Aprendizaje Automático**, el algoritmo **eXtreme Gradient Boosting (XGBoost)** se ha consolidado como una herramienta fundamental para la toma de decisiones automatizada en entornos de alta complejidad. Actualmente, las instituciones demandan modelos predictivos con alta eficiencia en el manejo de datos multidimensionales, especialmente en áreas críticas como la **protección de infraestructuras de red SDN** [1], el **procesamiento de imágenes hiperespectrales para teledetección** [2], el **monitoreo clínico mediante señales de electroencefalografía (EEG)** [3], el **diagnóstico médico basado en aprendizaje dual** [4] y la **localización de precisión en entornos de sensores físicos** [5].

La proliferación de dispositivos conectados y la evolución de las arquitecturas digitales exigen que modelos basados en árboles de decisión, como XGBoost, procesen volúmenes masivos de información con baja latencia y alta robustez. En el ámbito de la **seguridad de red**, las organizaciones enfrentan ataques de denegación de servicio (DDoS) que comprometen controladores centrales [1]. Paralelamente, en la **observación terrestre**, el análisis hiperespectral requiere una selección de bandas precisa para aplicaciones agrícolas y militares [2].

Por otro lado, en el sector de la **salud**, estas tecnologías permiten predecir convulsiones y estimar la severidad clínica de enfermedades con un alto rigor estadístico [3], [4]. Finalmente, en entornos industriales complejos, los sistemas de posicionamiento deben superar interferencias de señales sin línea de vista (NLOS) para garantizar la confiabilidad operativa [5]. La integración de XGBoost en estos diversos dominios resalta la necesidad de optimizar su arquitectura para responder a desafíos técnicos específicos de cada disciplina.

Situación actual basada en evidencia

Diversos estudios han evidenciado que el algoritmo XGBoost alcanza niveles de precisión superiores al 99.9 % en la detección de ataques de denegación de servicio distribuido (DDoS) [1] y presenta un rendimiento destacado en la predicción de convulsiones mediante señales de EEG con una exactitud del 92.31 % [3], mientras que otros autores indican que su arquitectura es altamente efectiva para la selección de bandas en imágenes hiperespectrales [2] y la clasificación de señales de banda ultraancha (UWB) en entornos complejos [5]. Asimismo, investigaciones recientes proponen evoluciones del marco original para realizar simultáneamente tareas de clasificación y regresión, logrando reducciones del tiempo de prueba de hasta un 81.9 % [4].

Sin embargo, persisten limitaciones relacionadas con el aislamiento operativo de las tareas predictivas en el marco convencional [4], la sensibilidad crítica ante el ruido y señales multipatía que pueden degradar la precisión significativamente [5], y la presencia de alta redundancia en la información interpretable multivariada (MII) [2], lo que exige un ajuste exhaustivo de hiperparámetros para evitar el sobreajuste [3].

1.2. Fundamentos Teóricos

Una red bayesiana calcula la distribución de probabilidad conjunta mediante la factorización de dependencias condicionales estructuradas en un grafo acíclico dirigido, expresada matemáticamente en la Ecuación 1.1:

$$P(X_1, X_2, \dots, X_n) = \prod_{i=1}^n P(X_i \mid \text{Padres}(X_i)) \tag{1.1}$$

1.3. Metodología y Análisis de la Literatura

A través de la metodología de jerarquización científica y la extracción de datos de artículos indexados en bases de datos de alto impacto [?], se estructuraron las dimensiones de rendimiento técnico explicadas en la Tabla 1.1.

Tabla 1.1: Dimensiones de análisis en redes probabilísticas clínicas.

Parámetro	Ventaja Tecnológica	Restricción
Cómputo	Consumo mínimo de memoria RAM	Complejidad algorítmica NP-Hard
Explicabilidad	Trazabilidad analítica exacta	Dependencia de expertos de dominio

1.4. Conclusiones

Las técnicas analíticas clásicas analizadas en este volumen proveen una base de explicabilidad matemática robusta, la cual es crucial para auditar las soluciones automatizadas modernas en la ingeniería de software actual.

Referencias

- [1] H. A. Alamri and V. Thayananthan, “Bandwidth control mechanism and extreme gradient boosting algorithm for protecting software-defined networks against ddos attacks,” *IEEE Access*, vol. 8, p. 194269–194288, 2020.
- [2] X. Shang, C. Cui, X. Sun, X. Wang, and J. Zhang, “Classification task-driven hyperspectral band selection via interpretability from xgboost,” *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, vol. 18, p. 13733–13754, 2025.
- [3] B. Kapoor and B. Nagpal, “Gradient boosting for predicting the relation between bio-medical signals and seizures using lgbm and xgboost,” *Journal of Mobile Multimedia*, p. 359–390, Mar. 2024.
- [4] R. Alwanin, O. Bchir, and M. M. B. Ismail, “Gradient boosting-based simultaneous classification and regression approach,” *IEEE Access*, vol. 13, p. 98557–98573, 2025.
- [5] S. Wang and N. S. Ahmad, “Robust classification of uwb nlos/los using combined fce and xgboost algorithms,” *IEEE Access*, vol. 12, p. 151030–151045, 2024.