

Reporte Técnico de Actividades Práctico-Experimentales Nro. 003

1. Datos de Identificación del Estudiante y la Práctica

Nombre del estudiante(s)	Cael Alejandro Soto Castillo
Asignatura	Metodología de la Investigación en Computación
Ciclo	4 A
Unidad	1
Resultado de aprendizaje de la unidad	R1. Contrasta la investigación y sus tipos con los métodos en el área de Computación y afines.
Práctica Nro.	003
Título de la Práctica	Identificación del problema preliminar de investigación
Nombre del Docente	Luis Antonio Chamba Eras
Fecha	Martes 28 de abril de 2026
Horario	10h30 – 11h30
Lugar	EVA / Aula
Tiempo planificado en el Sílabo	1 hora

2. Objetivo(s) de la Práctica

Identificar y documentar el problema preliminar de investigación del proyecto integrador, sus actores, contexto y variables o elementos centrales.

3. Materiales y Reactivos

- Computador.
- Plantilla de formulación del problema (EVA-Moodle).
- Fuentes bibliográficas recopiladas en APE 1.
- Mendeley / Zotero.
- EVA-Moodle y Guía institucional de práctica.

4. Equipos y Herramientas

- EVA-Moodle y Guía institucional de práctica.

5. Procedimiento / Metodología Ejecutada

Se aplicó la metodología de Aprendizaje Basado en Investigación (ABI) siguiendo los pasos establecidos:

1. Revisión de las fuentes bibliográficas recopiladas en la APE 1.
2. Identificación de brechas, necesidades o problemas detectados en la literatura.
3. Redacción de la descripción del problema preliminar usando la plantilla.
4. Identificación de actores involucrados, contexto y variables/elementos centrales.
5. Vinculación del problema con la sublínea de investigación seleccionada.

6. Resultados esperados

■ Contexto general del problema

En el marco de los **Sistemas Inteligentes y el Aprendizaje Automático**, el algoritmo **eXtreme Gradient Boosting (XGBoost)** se ha consolidado como una herramienta fundamental para la toma de decisiones automatizada en entornos de alta complejidad. Actualmente, las instituciones demandan modelos predictivos con alta eficiencia en el manejo de datos multidimensionales, especialmente en áreas críticas como la **protección de infraestructuras de red SDN [1]**, el **procesamiento de imágenes hiperespectrales para teledetección [2]**, el **monitoreo clínico mediante señales de electroencefalografía (EEG) [3]**, el **diagnóstico médico basado en aprendizaje dual [4]** y la **localización de precisión en entornos de sensores físicos [5]**.

La proliferación de dispositivos conectados y la evolución de las arquitecturas digitales exigen que modelos basados en árboles de decisión, como XGBoost, procesen volúmenes masivos de información con baja latencia y alta robustez. En el ámbito de la **seguridad de red**, las organizaciones enfrentan ataques de denegación de servicio (DDoS) que comprometen controladores centrales [1]. Paralelamente, en la **observación terrestre**, el análisis hiperespectral requiere una selección de bandas precisa para aplicaciones agrícolas y militares [2].

Por otro lado, en el sector de la **salud**, estas tecnologías permiten predecir convulsiones y estimar la severidad clínica de enfermedades con un alto rigor estadístico [3], [4]. Finalmente, en entornos industriales complejos, los sistemas de posicionamiento deben superar interferencias de señales sin línea de vista (NLOS) para garantizar la confiabilidad operativa [5]. La integración de XGBoost en estos diversos dominios resalta la necesidad de optimizar su arquitectura para responder a desafíos técnicos específicos de cada disciplina.

■ Situación actual basada en evidencia

Diversos estudios han evidenciado que el algoritmo XGBoost alcanza niveles de precisión superiores al 99.9 % en la detección de ataques de denegación de servicio distribuido (DDoS) [1] y presenta un rendimiento destacado en la predicción de convulsiones mediante señales de EEG con una exactitud del 92.31 % [3], mientras que otros autores indican que su arquitectura es altamente efectiva para la selección de bandas en imágenes hiperespectrales [2] y la clasificación de señales de banda ultraancha (UWB) en entornos complejos [5]. Asimismo, investigaciones recientes proponen evoluciones del marco original para realizar simultáneamente tareas de clasificación y regresión, logrando reducciones del tiempo de prueba de hasta un 81.9 %

[4]. Sin embargo, persisten limitaciones relacionadas con el aislamiento operativo de las tareas predictivas en el marco convencional [4], la sensibilidad crítica ante el ruido y señales multipatía que pueden degradar la precisión significativamente [5], y la presencia de alta redundancia en la información interpretable multivariada (MII) [2], lo que exige un ajuste exhaustivo de hiperparámetros para evitar el sobreajuste [3].

■ Brecha o vacío identificado

Tipo	Descripción	Fragmento	Cita	Implicancia
Problema de Escalabilidad	Dificultad para configurar intervalos de recolección en tiempo real sin comprometer el rendimiento del controlador.	"Although collecting traffic features in short time intervals can improve detection accuracy, it also increases processing and communication overhead, leading to controller saturation."	[1]	Compromete el equilibrio crítico entre la latencia de detección y la carga de procesamiento en redes SDN.
Brecha de Conocimiento	La integración secuencial de árboles de decisión genera una redundancia excesiva en la selección de características.	"It also results in high redundancy in MII (Multivariate Interpretable Information), as similar bands tend to share similar split gains during the boosting process."	[2]	Dificulta la reducción de dimensionalidad efectiva y la selección de variables óptimas en datos hiperespectrales.
Necesidad Metodológica	El crecimiento estructural de los árboles exige una sintonización de parámetros más compleja que otros modelos.	"One of the key distinctions is that the XGBoost algorithm tree develops depth-wise, which requires a more exhaustive technical adjustment of hyperparameters to avoid overfitting."	[3]	Incrementa la complejidad computacional y el tiempo de optimización necesario para alcanzar el rendimiento pico en salud.
Limitación Técnica	Tratamiento aislado de tareas de clasificación y regresión, impidiendo la captura de dependencias mutuas.	"Conventional supervised learning approaches typically train separate models for classification and regression, ignoring the sequential and complementary dependencies between tasks."	[4]	Genera ineficiencia operativa y duplicidad de recursos computacionales en aplicaciones de diagnóstico dual.
Limitación Técnica	Vulnerabilidad del modelo ante ruidos ambientales y señales multipatía en espacios cerrados.	"Accuracy can decrease in complex indoor environments due to NLOS (Non-Line-of-Sight) conditions, with performance dropping significantly without external pre-processing."	[5]	Reduce la fiabilidad de los sistemas de posicionamiento inteligente en entornos industriales de misión crítica.

■ Enfoques Metodológicos

Trabajos	Cuanti.	Cuali.	Mixto	Observación
[1]	X			Presenta un enfoque cuantitativo basado en el diseño y validación experimental de un esquema de mitigación de ataques DDoS en redes SDN. Utiliza métricas de rendimiento como precisión (99.9 %) y tasa de falsos positivos (0.0002 %) obtenidas tras evaluar el algoritmo XGBoost con conjuntos de datos numéricos estandarizados como CICDDoS2019, NSL-KDD y CAIDA.
[2]	X			Su metodología es puramente cuantitativa al proponer el método XGBS para la selección de bandas en imágenes hiperespectrales. El estudio se fundamenta en la optimización de una función de pérdida y la validación mediante métricas estadísticas de clasificación como la Exactitud General (OA), Exactitud Promedio (AA) y el coeficiente Kappa a través de experimentos en seis conjuntos de datos reales.
[3]	X			Emplea un enfoque cuantitativo centrado en el análisis matemático y el aprendizaje de conjunto para la clasificación de señales biomédicas EEG. La investigación recolecta datos numéricos procesados mediante PCA para reducción de dimensionalidad y valida el modelo XGBoost usando validación cruzada de 10 pliegues, reportando métricas precisas de sensibilidad (90.18 %) y especificidad (90.04 %).
[4]	X			Este trabajo sigue una metodología cuantitativa al desarrollar el marco unificado DXGBA para tareas duales de clasificación y regresión. El rigor científico se establece mediante la minimización de una función de costo conjunta y el uso de pruebas de significancia estadística (t-test de pares, Wilcoxon y Shapiro-Wilk) para comparar resultados numéricos de F1-score y MSE frente a modelos convencionales.
[5]	X			Posee un enfoque cuantitativo basado en la clasificación robusta de señales UWB mediante la combinación de FCE y XGBoost. El estudio utiliza métodos estadísticos como el Coeficiente de Correlación de Pearson para selección de características y técnicas numéricas (Z-score, IQR, DBSCAN) para el manejo de valores atípicos, validando los resultados con métricas de precisión (94.8 %) y recall (90.3 %).

■ Problema central

El problema radica en la **arquitectura operativa silocada y la carencia de resiliencia intrínseca del algoritmo XGBoost ante la complejidad de los datos [4]**, lo que se manifiesta en la incapacidad nativa para integrar simultáneamente tareas de clasificación y regresión [4], la generación de alta redundancia técnica en la selección de características óptimas (MII) por el mecanismo de boosting [2] y una

degradación significativa de la precisión ante ruidos ambientales o la falta de una sintonización exhaustiva de hiperparámetros [3], [5], lo cual afecta directamente a la **eficiencia operativa, la economía de recursos computacionales y la confiabilidad de los sistemas inteligentes de posicionamiento, diagnóstico clínico y ciberseguridad en entornos de misión crítica** [1], [3], [5].

■ Consecuencias o impacto

Esta situación genera consecuencias como la saturación del ancho de banda y la potencial falla de los controladores en redes definidas por software (SDN) ante ataques DDoS [1], el incremento en el riesgo de accidentes físicos y el desarrollo de estados depresivos en pacientes neurológicos debido a la incapacidad de predecir crisis de forma precisa [3], y errores de posicionamiento que comprometen la fiabilidad de la localización en entornos industriales o médicos complejos [5].

Asimismo, la alta redundancia en datos hiperespectrales [2] y el procesamiento aislado de tareas de clasificación y regresión [4] provocan un desperdicio de recursos computacionales, dificultando la transmisión eficiente de la información. Esta situación limita la capacidad de respuesta en tiempo real y la robustez de los sistemas inteligentes en dominios de misión crítica donde la precisión y la economía de recursos son fundamentales [1], [4], [5].

■ Actores involucrados

Los principales actores involucrados incluyen a los **administradores de red y especialistas en ciberseguridad** [1], quienes requieren herramientas precisas para proteger la disponibilidad de servicios en redes SDN. En el ámbito sanitario, destacan el **personal clínico, investigadores médicos y pacientes con trastornos neurológicos** [3], [4], como epilepsia o Alzheimer, quienes dependen de la eficiencia del algoritmo para la predicción de convulsiones y el diagnóstico de la severidad clínica.

Asimismo, se identifican como afectados a los **ingenieros de sistemas de posicionamiento y expertos en teledetección** [2], [5] en sectores de manufactura, minería y agricultura, los cuales emplean el procesamiento de señales e imágenes hiperespectrales para tareas de localización y clasificación de objetos en entornos complejos. Finalmente, el problema impacta a las **organizaciones tecnológicas** [1], [4] que desarrollan marcos de aprendizaje automático para la toma de decisiones automatizada en sistemas de misión crítica.

■ Variables o elementos clave

Los elementos clave que intervienen en este problema son la **precisión de clasificación** en la detección de ataques y diagnósticos clínicos [1], [3], la **latencia de detección** y el **overhead de procesamiento y comunicación** en sistemas de seguridad de red en tiempo real [1], y la **Información Interpretable Multivariada (MII)** requerida para mitigar la redundancia en datos de alta dimensionalidad [2].

Asimismo, el rendimiento del algoritmo está definido por la **ganancia de división** (*split gain*) de las variables [2], las **dependencias secuenciales y complementarias** entre características [4], y métricas de error continuo como el **error cuadrático**

medio (MSE), el error absoluto medio (MAE) y la raíz del error cuadrático medio (RMSE) en tareas de regresión simultánea [4].

Finalmente, intervienen factores como la **robustez ante el ruido NLOS** [5], los **hiperparámetros del modelo** —incluyendo la tasa de aprendizaje (*eta*), la profundidad máxima y el ratio de submuestreo— [3], y la eficacia en el **manejo de valores atípicos** mediante métodos estadísticos y de agrupamiento [5].

■ Delimitación del problema

Esta investigación se delimita al análisis del algoritmo **eXtreme Gradient Boosting (XGBoost)** [1] y sus variantes técnicas, tales como el modelo de aprendizaje dual **DXGBA** [4] para la ejecución simultánea de tareas de clasificación y regresión, y el marco **Light Gradient Boosting Machine (LGBM)** [3] para el procesamiento de señales de alta velocidad. El estudio considera factores fundamentales como la optimización de hiperparámetros (tasa de aprendizaje, profundidad máxima y número de árboles) [3], la reducción de la redundancia en la Información Interpretatable Multivariada (MII) [2], y la mejora de la eficiencia operativa mediante la reducción del tiempo de prueba y el *overhead* de procesamiento [4]. Asimismo, el alcance técnico se restringe al procesamiento de tipos de datos específicos que incluyen señales de electroencefalografía (EEG) [3], perfiles de tráfico SDN [1], imágenes hiperespectrales [2] y datos de Respuesta al Impulso del Canal (CIR) en entornos UWB [5].

Por el contrario, esta investigación excluye el análisis de arquitecturas de redes neuronales profundas que no operen como base de comparación directa, la exploración de fenómenos físicos de difracción de señales que no estén capturados en los datos digitales analizados [5] y la implementación de sistemas de seguridad en redes SDN con arquitecturas de múltiples controladores [1].

■ Vinculación con la sublínea de investigación

Este problema se enmarca dentro de la sublínea de investigación **Sistemas Inteligentes**, debido a su enfoque en la **concepción, optimización y despliegue de modelos predictivos avanzados** que permiten la toma de decisiones autónoma y precisa en entornos de alta complejidad algorítmica. La investigación se alinea con la necesidad de evolucionar las arquitecturas de aprendizaje supervisado, como **XGBoost**, para superar limitaciones estructurales en el procesamiento de datos masivos y multidimensionales, garantizando la eficiencia operativa en sistemas críticos [1], [4].

La vinculación técnica se justifica mediante el desarrollo de **modelos predictivos robustos** capaces de capturar relaciones no lineales en señales de diversa naturaleza, tales como electroencefalogramas para la predicción de crisis convulsivas [3] o respuestas al impulso del canal en sistemas de posicionamiento UWB [5]. Asimismo, el estudio aborda la **optimización de algoritmos de aprendizaje automático** a través del ajuste fino de hiperparámetros y la reducción de la redundancia en la Información Interpretatable Multivariada (MII) [2], aspectos fundamentales para mejorar la capacidad de generalización del modelo.

Finalmente, la integración de marcos de **aprendizaje dual** para la resolución simultánea de problemas de clasificación y regresión [4], junto con el diseño de mecanismos de mitigación de amenazas en redes de nueva generación [1], refuerza

la pertenencia a esta sublínea. Estos esfuerzos buscan equilibrar la **economía de recursos computacionales** con una alta precisión predictiva, satisfaciendo los estándares de los **Sistemas Inteligentes** modernos aplicados a la ciberseguridad, la salud y la industria 4.0.

7. Preguntas de Control

- **¿Qué diferencia existe entre un problema práctico y un problema de investigación?**

Un problema práctico es una situación del mundo real que requiere una acción o producto para ser resuelta, como un fallo técnico específico, mientras que un problema de investigación es un vacío de conocimiento científico que requiere el método científico para ser comprendido. Mientras el primero busca una solución utilitaria, el segundo busca generar nuevo conocimiento que sea generalizable y validado.

- **¿Cómo se justifica la relevancia de un problema de investigación en computación?**

La relevancia se justifica demostrando el impacto técnico en la optimización de recursos, la mejora de la precisión algorítmica o la resolución de brechas en el estado del arte que la literatura actual no ha cubierto. Además, se fundamenta en su utilidad social y económica, explicando cómo la solución propuesta beneficia a sectores críticos como la salud, la ciberseguridad o la industria mediante el avance tecnológico.

8. Conclusiones

- Se identificó con éxito el problema preliminar de investigación, determinando que la raíz del conflicto técnico reside en la arquitectura operativa silocada de XGBoost y su limitada resiliencia ante datos de alta complejidad. A través de la revisión literaria, se constató que la incapacidad nativa del algoritmo para integrar tareas de clasificación y regresión simultáneamente, sumada a la degradación de precisión en entornos con ruido, constituye un vacío de conocimiento crítico que justifica el desarrollo de nuevas metodologías dentro del campo del aprendizaje automático.
- La documentación de los actores y el contexto permitió situar el problema en un entorno de aplicación real, vinculando la eficiencia del algoritmo con sectores estratégicos como la ciberseguridad, la salud y el posicionamiento industrial. Al definir a los interesados —desde administradores de red hasta pacientes con trastornos neurológicos— se estableció el impacto humano y operativo de la investigación, demostrando que la optimización de los modelos predictivos no es solo una mejora técnica, sino una necesidad para la seguridad y fiabilidad de los sistemas de misión crítica.
- Finalmente, se definieron las variables y elementos centrales del estudio, tales como la Información Interpretable Multivariada (MII), el *overhead* de procesamiento y las métricas de error cuadrático, logrando una delimitación precisa del alcance del proyecto. Esta caracterización técnica facilitó la vinculación directa con la sublínea de Sistemas Inteligentes, asegurando que el proyecto integrador cumpla con los estándares académicos de la carrera al enfocarse en la optimización de parámetros y la reducción de redundancia en datos multidimensionales.

9. Recomendaciones

- Se recomienda profundizar en la sintonización de hiperparámetros específicos como la tasa de aprendizaje (*eta*) y la profundidad del árbol, con el fin de mitigar la degradación de precisión identificada en el problema central ante datos con alta variabilidad.
- Es sugerible priorizar la implementación de mecanismos de reducción de redundancia, como la Información Interpretable Multivariada (MII), para optimizar el consumo de recursos computacionales y mejorar la velocidad de procesamiento en entornos de misión crítica.
- Se aconseja validar los modelos resultantes mediante una comparación directa entre el algoritmo XGBoost estándar y variantes más ligeras o duales (LGBM o DXGBA), asegurando así que la solución propuesta sea la más eficiente para los tipos de datos analizados.

10. Bibliografía / Referencias

- [1] H. A. Alamri and V. Thayananthan, "Bandwidth Control Mechanism and Extreme Gradient Boosting Algorithm for Protecting Software-Defined Networks Against DDoS Attacks," *IEEE Access*, vol. 8, pp. 192801-192813, oct. 2020, doi: 10.1109/ACCESS.2020.3033942.
- [2] X. Shang, C. Cui, X. Sun, X. Wang and J. Zhang, "Classification Task-Driven Hyperspectral Band Selection via Interpretability From XGBoost," *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, vol. 18, pp. 7837-7853, mayo 2025, doi: 10.1109/JSTARS.2025.3572278.
- [3] B. Kapoor and B. Nagpal, "Gradient Boosting for Predicting the Relation Between Bio-medical Signals and Seizures Using LGBM and XGBoost," *Journal of Mobile Multimedia*, vol. 20, no. 2, pp. 359–390, marzo 2024, doi: 10.13052/jmm1550-4646.2025.
- [4] R. Alwanin, O. Bchir and M. M. B. Ismail, "Gradient Boosting-Based Simultaneous Classification and Regression Approach," *IEEE Access*, vol. 13, pp. 84144-84157, junio 2025, doi: 10.1109/ACCESS.2025.3576086.
- [5] S. Wang and N. S. Ahmad, "Robust Classification of UWB NLOS/LOS Using Combined FCE and XGBoost Algorithms," *IEEE Access*, vol. 12, pp. 153341-153355, oct. 2024, doi: 10.1109/ACCESS.2024.3480236.