

Matriz de Extracción de Artículos Científicos

Información general del estudiante (ejemplo)

- **Nombre del estudiante:** Cael Alejandro Soto Castillo
- **Técnica de IA:** XGBoost
- **Pregunta de investigación:** ¿Qué ventajas ofrece XGBoost en problemas de clasificación?
- **Cadena de búsqueda:**

Showing 1-25 of 70,981 results for
("All Metadata":"XGBoost") OR ("All Metadata":Extreme Gradient Boosting) AND ("All Metadata":classification) AND ("All Metadata":performance) OR ("All Metadata":evaluation) OR ("All Metadata":accuracy) ✕

Matriz de extracción (ejemplo con 5 artículos)

#	Referencia (IEEE)	Año	Base de datos	Técnica IA	Problema abordado	Objetivo del artículo	Metodología	Dataset / Contexto	Resultados principales	Limitaciones	Aporte para la PI
1	H. A. Alamri and V. Thayananthan, "Bandwidth Control Mechanism and Extreme Gradient Boosting Algorithm for Protecting Software-Defined Networks Against DDoS Attacks," IEEE Access, vol. 8, 2020.	2020	IEEE Xplore	Extreme Gradient Boosting (XGBoost)	Ataques DDoS en redes SDN	Desarrollar un marco de seguridad híbrido para detectar y mitigar DDoS	Clasificación de tráfico mediante XGBoost combinada con una política de control de ancho de banda	Dataset CICDDoS2019 (escenarios de reflexión y explotación)	Precisión (Accurac y) del 99.1% y F1-Score del 99.2% en la detección de ataques	El rendimiento puede degradarse si el controlador SDN se sobrecarga antes de la mitigación	Provee un modelo de defensa proactiva que no solo detecta, sino que gestiona recursos de red
2	S. Kim, "A Lightweight Intelligent Network Intrusion Detection System for Industrial IoT Using One-Dimensional Convolutional Neural Network," IEEE Access, vol. 11, pp. 118431-118445, 2023.	2023	IEEE Xplore	1D-CNN (Red Neuronal Conv olucional 1D)	Intrusiones y ataques en redes de IoT Industrial (IIoT)	Desarrollar un sistema de detección de intrusiones (NIDS) ligero y eficiente	Uso de redes convolucionales 1D para extraer características de tráfico sin alta carga computacional	Dataset s Edge-IIoTset y UNSW-NB15	Precisión del 99.42% y 99.16% con un tiempo de inferencia extremadamente bajo	La eficacia depende de la calidad del preprocesamiento de los datos de red	Demuestra la viabilidad de usar aprendizaje profundo en dispositivos con recursos limitados
3	M. S. Uddin, J. B. Al-Siddiki and J. S. S. Shovon, "Gradient Boosting for Predicting the	2023	IEEE Xplore	XGBoost y Light GBM (LG	Predicción de convulsiones epilépticas mediante	Comparar el rendimiento de modelos de Boosting para predecir	Aplicación de ingeniería de características sobre señales	UCI Machine Learning Repository	XGBoost logró una precisión del 97.43% y LGBM del	Alta dependencia del preprocesamiento de señales ruidosas de	Valida el uso de XGBoost para análisis de

	Relation Between Bio-Medical Signals and Seizures Using LGBM and XGBoost," 2023 5th International Conference on Sustainable Technologies for Industry 5.0 (STI), Dhaka, Bangladesh, 2023.			BM) Predicción de convulsiones epilépticas mediante señales de EEG	señales de EEG	ataques epilépticos	EEG y entrenamiento de modelos de Boosting	(Epileptic Seizure Recognition Dataset)	97.13%	EEG	series temporales y eventos críticos
4	T.-Y. Lin et al., "Feature Pyramid Networks," IEEE CVPR	2017	IEEE	CNN	Detección multiescala	Mejorar detección de objetos pequeños	Pirámides de características	COCO	Mejora en objetos pequeños	Mayor consumo computacional	Mejora robustez
5	J. Dai et al., "R - F C N : Object Detection via Region-based Fully Convolutional Networks," IEEE NIPS	2016	IEEE	CNN	Detección eficiente	Reducir costo computacional	Fully convolutional networks	VOC	Mejor eficiencia	Menor flexibilidad	Optimiza eficiencia

Síntesis del ejemplo (modelo que el estudiante debe replicar)

Las CNN han demostrado ser altamente efectivas en la detección de objetos dentro del campo de visión por computador. Los estudios analizados evidencian una evolución progresiva desde modelos como R-CNN hacia enfoques más eficientes como YOLO y Faster R-CNN. Mientras que modelos como Fast R-CNN priorizan la precisión mediante el análisis por regiones, YOLO introduce un enfoque unificado que permite detección en tiempo real. Por otro lado, técnicas como Feature Pyramid Networks mejoran el rendimiento en la detección de objetos de diferentes escalas. En general, existe un trade-off entre precisión y eficiencia computacional.

Respuesta a la pregunta de investigación (ejemplo)

Las CNN se aplican en la detección de objetos mediante arquitecturas especializadas que permiten identificar y localizar múltiples objetos dentro de una imagen. Estas técnicas han evolucionado hacia modelos más rápidos y precisos, como YOLO y Faster R-CNN, los cuales logran un equilibrio entre rendimiento y eficiencia, siendo ampliamente utilizados en aplicaciones como vehículos autónomos, vigilancia inteligente y análisis de imágenes médicas.