



Universidad
Nacional
de Loja

Universidad Nacional de Loja

Facultad de la Energía, las Industrias y los Recursos Naturales
No Renovables

Carrera de Computación

Formulación de preguntas de investigación y objetivos
aplicando criterios SMART

Workshop on formulating research questions and
objectives using SMART criteria

Metodología de la Investigación en
Computación.

AUTOR:

Cael Alejandro Soto Castillo

TUTOR:

Prof. Luis Chamba-Eras

Loja, Ecuador

2026

Declaración de uso de IA Generativa

Yo, **Cael Alejandro Soto Castillo**, en calidad de autor, declaro de manera transparente y responsable el uso de herramientas de Inteligencia Artificial Generativa (IAG) durante el desarrollo del presente trabajo, en conformidad con los principios de integridad académica, ética investigativa y buenas prácticas en el uso de tecnologías emergentes.

1. Alcance del uso de IA generativa

El uso de herramientas de IAG se ha limitado a funciones de apoyo, sin sustituir el juicio crítico ni la autoría intelectual del autor. En particular, se han utilizado para:

- **Mejora de redacción y estilo académico:** Optimización de la narrativa técnica en la descripción de algoritmos de Machine Learning.
- **Generación de ideas preliminares:** Estructuración de los niveles de investigación (descriptivo, aplicado y experimental).
- **Apoyo en la estructuración del documento:** Organización de secciones en formato LaTeX y jerarquización de contenidos.
- **Asistencia técnica:** Depuración de errores de compilación en entornos de listas y formato de ecuaciones matemáticas.

2. Clasificación del uso según GAIDeT

De acuerdo con la taxonomía GAIDeT, el uso de IA generativa en este trabajo se clasifica en:

- **Nivel 1 – Asistencia Lingüística:** Corrección gramatical y mejora de claridad en la redacción de los objetivos del estudio.
- **Nivel 2 – Apoyo en Ideación:** Esquematización de las variables independientes y dependientes para el análisis de ataques DDoS.

- **Nivel 3 – Asistencia Técnica:** Apoyo en la generación de fragmentos de código LaTeX para la visualización de algoritmos y tablas comparativas de modelos (XGBoost, SVM, RF).

No se ha utilizado IA generativa para la generación autónoma de resultados ni para sustituir el análisis crítico del autor.

3. Validación y responsabilidad

Todo contenido asistido por IA ha sido revisado, validado y adaptado por el autor, quien asume la responsabilidad total sobre la calidad, veracidad y originalidad del trabajo. Se verificó manualmente que las citas y referencias técnicas correspondan a la literatura científica vigente.

4. Herramientas utilizadas

Se emplearon modelos de lenguaje avanzados (Gemini) como herramientas de asistencia técnica para la redacción de la estructura del documento y el apoyo conceptual en la definición de métricas de redes SDN.

5. Consideraciones éticas

El uso de IA se realizó respetando principios de honestidad académica, normativas institucionales de la **Universidad Nacional de Loja** y buenas prácticas internacionales para la transparencia en la investigación técnica.

6. Declaración final

Declaro que el uso de IA generativa ha sido ético, transparente y complementario, sin comprometer la autoría ni la integridad académica del presente trabajo.

Loja, Ecuador, 6 de mayo de 2026

Cael Alejandro Soto Castillo
Autor

Índice General

Declaración de uso de IA Generativa	1
1 Título	5
2 Resumen	6
3 Abstract	7
4 Introducción	8
5 Resultados	10
Referencias bibliográficas	27

Índice de Tablas

5.1	Análisis de brechas técnicas y limitaciones de XGBoost	10
5.2	Enfoques metodológicos de las fuentes consultadas	14
5.3	Preguntas de Investigación según Nivel Taxonómico	21
5.4	Categorización de Fuentes Basada en las Preguntas de Investigación . .	23

1. Título

Formulación de preguntas de investigación y objetivos aplicando criterios SMART

2. Resumen

El algoritmo XGBoost (*Extreme Gradient Boosting*) se posiciona como una de las técnicas de aprendizaje supervisado más eficientes y robustas dentro del campo de la inteligencia artificial y el análisis predictivo. Basado en ensambles de árboles de decisión y en el principio de potenciación por gradiente, este modelo destaca por su capacidad para capturar relaciones no lineales complejas, optimizar el rendimiento computacional y reducir el sobreajuste mediante técnicas de regularización y aprendizaje aditivo. En

el ámbito de la ciberseguridad, las investigaciones revisadas evidencian que XGBoost alcanza niveles de precisión de hasta 99.9 % en la detección de ataques DDoS sobre redes SDN, manteniendo tasas mínimas de falsos positivos y una elevada eficiencia en el procesamiento paralelo. Asimismo, en aplicaciones de análisis hiperespectral, el modelo permite identificar variables relevantes mediante el análisis de ganancias de división y dependencias estructurales entre nodos, favoreciendo procesos efectivos de selección de bandas. Dentro del campo biomédico, XGBoost demuestra un alto desempeño en la

clasificación de señales EEG para la predicción de convulsiones epilépticas, superando a otros modelos de aprendizaje automático en precisión, sensibilidad y especificidad. De igual manera, propuestas recientes como el marco DXGBA amplían las capacidades tradicionales del algoritmo al integrar simultáneamente tareas de clasificación y regresión bajo una estructura compartida de optimización, mejorando la eficiencia computacional y reduciendo tiempos de procesamiento. Finalmente, en sistemas de posicionamiento en

interiores, la combinación de XGBoost con métodos de evaluación difusa permite clasificar señales UWB con latencias extremadamente bajas y alta estabilidad operativa. En conjunto, la literatura revisada evidencia que XGBoost constituye una herramienta versátil, escalable y de alta precisión, capaz de adaptarse exitosamente a diversos contextos tecnológicos y científicos con requerimientos computacionales reducidos.

Palabras clave: XGBoost, aprendizaje supervisado, inteligencia artificial, clasificación, regresión, redes SDN, ciberseguridad.

3. Abstract

The XGBoost (*Extreme Gradient Boosting*) algorithm is recognized as one of the most efficient and robust supervised learning techniques in the fields of artificial intelligence and predictive analytics. Based on tree ensemble learning and gradient boosting principles, this model is capable of capturing complex nonlinear relationships while optimizing computational performance and reducing overfitting through regularization and additive learning strategies. In cybersecurity applications, the reviewed studies demonstrate that XGBoost achieves accuracy rates of up to 99.9% in detecting Distributed Denial-of-Service (DDoS) attacks within Software-Defined Networks (SDN), maintaining extremely low false-positive rates and high parallel processing efficiency. Likewise, in hyperspectral image analysis, the algorithm enables effective feature selection through split-gain evaluation and structural dependency analysis between decision tree nodes. Within the biomedical domain, XGBoost exhibits outstanding performance in EEG signal classification for epileptic seizure prediction, outperforming several alternative machine learning approaches in accuracy, sensitivity, and specificity. Furthermore, recent developments such as the DXGBA framework extend the traditional capabilities of XGBoost by integrating classification and regression tasks into a unified optimization structure, significantly improving computational efficiency and reducing processing time. In indoor positioning systems, the integration of XGBoost with Fuzzy Comprehensive Evaluation methods enables accurate classification of UWB signals while maintaining extremely low latency and high operational stability. Overall, the reviewed literature highlights XGBoost as a versatile, scalable, and highly accurate algorithm capable of adapting successfully to diverse scientific and technological scenarios with relatively low computational requirements.

Keywords: XGBoost, supervised learning, artificial intelligence, classification, regression, SDN networks, cybersecurity.

4. Introducción

Contexto general del problema

En el marco de los **Sistemas Inteligentes y el Aprendizaje Automático**, el algoritmo **eXtreme Gradient Boosting (XGBoost)** se ha consolidado como una herramienta fundamental para la toma de decisiones automatizada en entornos de alta complejidad. Actualmente, las instituciones demandan modelos predictivos con alta eficiencia en el manejo de datos multidimensionales, especialmente en áreas críticas como la **protección de infraestructuras de red SDN [1]**, el **procesamiento de imágenes hiperspectrales para teledetección [2]**, el **monitoreo clínico mediante señales de electroencefalografía (EEG) [3]**, el **diagnóstico médico basado en aprendizaje dual [4]** y la **localización de precisión en entornos de sensores físicos [5]**.

La proliferación de dispositivos conectados y la evolución de las arquitecturas digitales exigen que modelos basados en árboles de decisión, como XGBoost, procesen volúmenes masivos de información con baja latencia y alta robustez. En el ámbito de la **seguridad de red**, las organizaciones enfrentan ataques de denegación de servicio (DDoS) que comprometen controladores centrales [1]. Paralelamente, en la **observación terrestre**, el análisis hiperspectral requiere una selección de bandas precisa para aplicaciones agrícolas y militares [2].

Por otro lado, en el sector de la **salud**, estas tecnologías permiten predecir convulsiones y estimar la severidad clínica de enfermedades con un alto rigor estadístico [3], [4]. Finalmente, en entornos industriales complejos, los sistemas de posicionamiento deben superar interferencias de señales sin línea de vista (NLOS) para garantizar la confiabilidad operativa [5]. La integración de XGBoost en estos diversos dominios resalta la necesidad de optimizar su arquitectura para responder a desafíos técnicos específicos de cada disciplina.

Situación actual basada en evidencia

Diversos estudios han evidenciado que el algoritmo XGBoost alcanza niveles de

precisión superiores al 99.9 % en la detección de ataques de denegación de servicio distribuido (DDoS) [1] y presenta un rendimiento destacado en la predicción de convulsiones mediante señales de EEG con una exactitud del 92.31 % [3], mientras que otros autores indican que su arquitectura es altamente efectiva para la selección de bandas en imágenes hiperespectrales [2] y la clasificación de señales de banda ultraancha (UWB) en entornos complejos [5]. Asimismo, investigaciones recientes proponen evoluciones del marco original para realizar simultáneamente tareas de clasificación y regresión, logrando reducciones del tiempo de prueba de hasta un 81.9 % [4].

Sin embargo, persisten limitaciones relacionadas con el aislamiento operativo de las tareas predictivas en el marco convencional [4], la sensibilidad crítica ante el ruido y señales multipatía que pueden degradar la precisión significativamente [5], y la presencia de alta redundancia en la información interpretable multivariada (MII) [2], lo que exige un ajuste exhaustivo de hiperparámetros para evitar el sobreajuste [3].

5. Resultados

Estado de la Cuestión y Problema de Investigación

BRECHA O VACÍO IDENTIFICADO:

Tabla 5.1: Análisis de brechas técnicas y limitaciones de XGBoost

Tipo	Descripción	Fragmento	Cita	Implicancia
Problema de Escalabilidad	Dificultad para configurar intervalos de recolección en tiempo real sin comprometer el rendimiento del controlador.	“Although collecting traffic features in short time intervals can improve detection accuracy, it also increases processing and communication overhead, leading to controller saturation.”	[1]	Compromete el equilibrio crítico entre la latencia de detección y la carga de procesamiento en redes SDN.
Brecha de Conocimiento	La integración secuencial de árboles de decisión genera una redundancia excesiva en la selección de características.	“It also results in high redundancy in MII (Multivariate Interpretable Information), as similar bands tend to share similar split gains during the boosting process.”	[2]	Dificulta la reducción de dimensionalidad efectiva y la selección de variables óptimas en datos hiperespectrales.
Necesidad Metodológica	El crecimiento estructural de los árboles exige una sintonización de parámetros más compleja que otros modelos.	“One of the key distinctions is that the XGBoost algorithm tree develops depth-wise, which requires a more exhaustive technical adjustment of hyperparameters to avoid overfitting.”	[3]	Incrementa la complejidad computacional y el tiempo de optimización necesario para alcanzar el rendimiento pico en salud.

Tipo	Descripción	Fragmento	Cita	Implicancia
Limitación Técnica	Tratamiento aislado de tareas de clasificación y regresión, impidiendo la captura de dependencias mutuas.	“Conventional supervised learning approaches typically train separate models for classification and regression, ignoring the sequential and complementary dependencies between tasks.”	[4]	Genera ineficiencia operativa y duplicidad de recursos computacionales en aplicaciones de diagnóstico dual.
Limitación Técnica	Vulnerabilidad del modelo ante ruidos ambientales y señales multipatía en espacios cerrados.	“Accuracy can decrease in complex indoor environments due to NLOS (Non-Line-of-Sight) conditions, with performance dropping significantly without external pre-processing.”	[5]	Reduce la fiabilidad de los sistemas de posicionamiento inteligente en entornos industriales de misión crítica.
Eficiencia	Riesgo de sobreajuste en redes neuronales frente a la estabilidad de los modelos de ensamble.	“more complex ANN configurations sometimes performed worse... due to overfitting issues and the significant effort required for hyperparameter tuning.”	[6]	Demuestra que XGBoost es más robusto que las ANN en el modelado de espacios no continuos altamente variables.
Modelado	Dificultad intrínseca para capturar interacciones no lineales profundas en datos de consumo masivo.	“challenges in capturing the nonlinear relationship between consumer behavior factors... feeding these features as input into the XGBoost model to further optimize accuracy.”	[7]	Sugiere que XGBoost requiere una capa previa de DNN para una extracción de características eficaz en sistemas de optimización.
Optimización	Sensibilidad crítica del rendimiento a la configuración de los parámetros del Booster.	“The Booster parameter has a significant impact on algorithm performance... each type of parameter includes multiple specific parameters, totaling up to dozens.”	[8]	El éxito del despliegue en entornos industriales depende de un ajuste metaheurístico riguroso para evitar la inestabilidad.

Tipo	Descripción	Fragmento	Cita	Implicancia
Generalización	Escasez de diversidad en conjuntos de datos para aplicaciones clínicas críticas de detección.	“demand for larger and more diverse EEG datasets for increasing model generality... proving robust in capturing those complex patterns.”	[9]	La falta de datos heterogéneos limita la capacidad del modelo para generalizar predicciones en poblaciones clínicas variadas.
Escalabilidad	Restricción en la escala y variedad de datos textuales para aplicaciones prácticas globales.	“scale and diversity of the experimental dataset are limited, so it may be difficult to fully reflect practical application.”	[10]	Limita la validez externa de los resultados en tareas de reconocimiento de texto fuera del dominio automatizado específico.
Transparencia	Opacidad de los modelos de ensamble que dificulta la interpretabilidad de las decisiones humanas.	“outcomes of random forest and XGBoost lack transparency... they are poorly interpretable and explainable... capturing non-linear relationships, which are intrinsically unintelligible.”	[11]	El alto rendimiento sacrifica la inteligibilidad necesaria para decisiones en sectores sensibles como seguros o justicia.
Arquitectura	Incapacidad para capturar correlaciones directas entre etiquetas en problemas multi-etiqueta complejos.	“mIXGPR has is that it is unable to capture correlations between labels... lower performing labels are put later in the chain.”	[12]	Obliga al uso de estrategias externas de cadenas de clasificadores para modelar dependencias biológicas en rutas metabólicas.
Convergencia	Inestabilidad y riesgo de sobreajuste ante configuraciones de hiperparámetros subóptimas.	“performance is highly dependent on hyperparameter tuning, and suboptimal configurations frequently lead to overfitting or unstable behavior.”	[13]	Demanda el uso de optimizadores globales (como BES) para asegurar la confiabilidad en ciberseguridad en la nube.

Tipo	Descripción	Fragmento	Cita	Implicancia
Seguridad	Vulnerabilidad ante inyecciones de datos y ataques Man-in-the-Middle en dispositivos médicos.	“Attackers and intruders aim to impair data integrity... with the prevalence of sophisticated cyber attacks... like spoofing and data injection.”	[14]	Los modelos independientes pueden fallar ante ataques coordinados, exigiendo arquitecturas de ensamble de votación suave (soft-voting).
Latencia	Compromiso crítico entre la estabilidad del aprendizaje y el tiempo total de entrenamiento.	“Lower learning rate generally promotes stable learning... albeit at the expense of increased training time due to the requirement for a larger number of trees.”	[15]	Introduce latencias significativas en el re-entrenamiento del modelo para monitoreo de herramientas en tiempo real.
Precisión	Ligera inferioridad técnica frente a modelos estandarizados de referencia completa en video.	“Our RR regression model is slightly less accurate than ITU-standardised models, but it can be used in lossy transmission environments.”	[16]	Aunque ofrece flexibilidad, sacrifica exactitud absoluta en la predicción del Mean Opinion Score (MOS) en redes inestables.
Interpretabilidad	Lógica de decisión opaca en validaciones de ingeniería civil con muestras reducidas.	“XGBoost 400 concrete samples... Fast inference Limited interpretability... lógica de decisión permanece opaca.”	[17]	Dificulta la validación estructural humana de los factores que determinan la productividad en obras de construcción.
Utilización	Deficiencia en el uso óptimo de características para el seguimiento del conocimiento educativo.	“KT models still have problems of inaccurate prediction results and poor features utilization... performance and efficiency of the knowledge tracing model.”	[18]	Degradación del rendimiento si no se realiza una ingeniería de características exhaustiva para capturar habilidades múltiples.

Tipo	Descripción	Fragmento	Cita	Implicancia
Balanceo	Detección ineficaz de clases minoritarias en ataques de ransomware raros pero críticos.	“majority of models still struggle with low recall for minority attack classes... low false-negative rate demonstrates the model effectively minimizes undetected intrusions.”	[19]	Los ataques raros pueden evadir la detección a menos que se apliquen técnicas arquitectónicas de balanceo de clases.
Distribución	Desafíos en el modelado de datos dispersos y distribuciones no normales en finanzas.	“structurally aligning with STIB enterprises’ unique characteristics: sparse data, non-normal distributions... effectively mitigate the risk of overfitting.”	[20]	Las funciones de pérdida estándar requieren regularización adicional para evitar la infravaloración de activos tecnológicos.

ENFOQUES METODOLÓGICOS:

Tabla 5.2: Enfoques metodológicos de las fuentes consultadas

Trabajo	Cuanti.	Cuali.	Mixto	Observación
[1]	X			Presenta un enfoque cuantitativo basado en el diseño y validación experimental de un esquema de mitigación de ataques DDoS en redes SDN. Utiliza métricas de rendimiento como precisión (99.9%) y tasa de falsos positivos (0.0002%) obtenidas tras evaluar el algoritmo XGBoost con conjuntos de datos numéricos estandarizados como CICDDoS2019, NSL-KDD y CAIDA.
[2]	X			Su metodología es puramente cuantitativa al proponer el método XGBS para la selección de bandas en imágenes hiperespectrales. El estudio se fundamenta en la optimización de una función de pérdida y la validación mediante métricas estadísticas de clasificación como la Exactitud General (OA), Exactitud Promedio (AA) y el coeficiente Kappa a través de experimentos en seis conjuntos de datos reales.

Trabajo	Cuanti.	Cuali.	Mixto	Observación
[3]	X			Emplea un enfoque cuantitativo centrado en el análisis matemático y el aprendizaje de conjunto para la clasificación de señales biomédicas EEG. La investigación recolecta datos numéricos procesados mediante PCA para reducción de dimensionalidad y valida el modelo XGBoost usando validación cruzada de 10 pliegues, reportando métricas precisas de sensibilidad (90.18 %) y especificidad (90.04 %).
[4]	X			Este trabajo sigue una metodología cuantitativa al desarrollar el marco unificado DXGBA para tareas duales de clasificación y regresión. El rigor científico se establece mediante la minimización de una función de costo conjunta y el uso de pruebas de significancia estadística (t-test de pares, Wilcoxon y Shapiro-Wilk) para comparar resultados numéricos de F1-score y MSE frente a modelos convencionales.
[5]	X			Posee un enfoque cuantitativo basado en la clasificación robusta de señales UWB mediante la combinación de FCE y XGBoost. El estudio utiliza métodos estadísticos como el Coeficiente de Correlación de Pearson para selección de características y técnicas numéricas (Z-score, IQR, DBSCAN) para el manejo de valores atípicos, validando los resultados con métricas de precisión (94.8 %) y recall (90.3 %).
[6]	X			Propone una metodología cuantitativa orientada a optimizar el tiempo de análisis de circuitos VLSI mediante clasificadores XGBoost acelerados por GPU. Reporta una mejora en el tiempo de ejecución de hasta 3.86x sobre métodos tradicionales, validando el desempeño con métricas de F1-score (0.934) en un conjunto de datos de un millón de etapas experimentales.

Trabajo	Cuanti.	Cuali.	Mixto	Observación
[7]	X			Utiliza un enfoque cuantitativo híbrido que integra redes neuronales profundas (DNN) con XGBoost para la predicción de decisiones de compra en el comercio electrónico. La investigación fundamenta su validez en el incremento de la precisión (84.7%) y el valor AUC (0.827) al procesar registros de transacciones y datos de comportamiento no lineales.
[8]			X	Adopta un enfoque mixto al emplear la Teoría Fundamentada (Grounded Theory) para la categorización cualitativa de indicadores ESG antes de su procesamiento cuantitativo con XGBoost.
[9]	X			Sigue una metodología cuantitativa basada en un modelo híbrido que combina XGBoost con arquitecturas RNN (LSTM y GRU) para la detección de convulsiones epilépticas. El rigor técnico se establece mediante validación cruzada y el reporte de un AUC de 0.995 y una precisión del 98.2% en el procesamiento de señales de electroencefalograma (EEG).
[10]	X			Aplica un enfoque cuantitativo para el reconocimiento de texto en el sector automotriz integrando ingeniería de características y XGBoost. La metodología incluye el preprocesamiento de datos mediante expresiones regulares y normalización de texto, validando la estabilidad y exactitud del modelo a través de una sintonización exhaustiva de hiperparámetros.
[11]	X			Presenta un marco de investigación cuantitativo denominado XCCSHAP para mejorar la interpretabilidad de modelos de ensamble. Utiliza la medida de asociación de Goodman-Kruskal y valores SHAP para el co-clustering de instancias y características, evaluando la fidelidad del modelo sustituto frente a XGBoost y Random Forest en diversos conjuntos de datos tabulares.

Trabajo	Cuanti.	Cuali.	Mixto	Observación
[12]	X			Emplea un enfoque cuantitativo centrado en la predicción de rutas metabólicas enzimáticas mediante el algoritmo mlXGPR. La metodología utiliza clasificación multi-etiqueta basada en XGBoost y se valida mediante el uso de métricas de pérdida de Hamming (Hamming loss), precisión y recall para modelar dependencias biológicas complejas.
[13]	X			Este trabajo sigue una metodología cuantitativa al integrar la optimización Bald Eagle Search (BES) con XGBoost para la detección de intrusiones en la nube. El estudio prioriza la transparencia mediante el uso de valores SHAP para explicar predicciones locales, logrando reducir significativamente la tasa de falsos negativos en entornos de ciberseguridad.
[14]	X			Posee un enfoque cuantitativo basado en una estrategia de ensamble por votación suave (soft-voting) que fusiona XGBoost y SVM para la seguridad en dispositivos IoMT. Valida su robustez frente a ataques Man-in-the-Middle con una precisión de hasta el 99.84 % y una tasa de recall del 99.53 % en conjuntos de datos como CICIDS-2017.
[15]	X			Sigue una metodología cuantitativa comparativa para predecir el desgaste de herramientas de corte en procesos de manufactura. Utiliza XGBoost junto a LightGBM y CatBoost para analizar el compromiso técnico entre la estabilidad del aprendizaje y el tiempo de entrenamiento, optimizando el rendimiento mediante mecanismos de corrección de errores residuales.
[16]	X			Presenta una investigación cuantitativa enfocada en el mapeo de métricas objetivas de calidad de video (SSIM y VMAF) hacia escalas subjetivas de Mean Opinion Score (MOS). El modelo XGBoost se optimiza mediante búsqueda en cuadrícula (grid search), reportando una reducción del error cuadrático medio (RMSE) a 0.31.

Trabajo	Cuanti.	Cuali.	Mixto	Observación
[17]	X			Emplea un enfoque cuantitativo para predecir la productividad laboral en la construcción mediante el análisis comparativo de ANN, SVM y XGBoost. La metodología aplica validación cruzada de cinco pliegues sobre 400 muestras de concreto, utilizando gráficos de dispersión para confirmar la convergencia entre valores reales y predichos.
[18]	X			Desarrolla un estudio cuantitativo en el ámbito educativo para el seguimiento del conocimiento del estudiante (Knowledge Tracing). Propone la optimización de la función objetivo de XGBoost mediante expansión de Taylor de segundo orden, validando la eficacia del modelo en la captura de habilidades múltiples con métricas de AUC sobresalientes.
[19]	X			Posee un enfoque cuantitativo centrado en la detección de ataques de ransomware mediante un modelo híbrido optimizado para Big Data. La investigación realiza un análisis de sensibilidad de características para identificar variables críticas de intrusión, demostrando una alta capacidad de recuperación y detección de clases minoritarias de ataque.
[20]			X	Adopta un enfoque mixto al correlacionar dimensiones cualitativas de gobernanza empresarial con modelos cuantitativos híbridos (XGBoost-GA-BP) para la valoración de empresas tecnológicas. La investigación reporta una alta fiabilidad con un coeficiente R2 superior al 97 % y un error MAPE inferior al 10 % en el análisis de 1558 observaciones financieras.

■ Problema central

El problema radica en la **arquitectura operativa silocada y la carencia de resiliencia intrínseca del algoritmo XGBoost ante la complejidad de los datos** [4], lo que se manifiesta en la incapacidad nativa para integrar simultáneamente tareas de clasificación y regresión [4], la generación de alta redundancia técnica en la selección de características óptimas (MII) por el mecanismo de boosting [2] y una degradación significativa de la precisión ante ruidos ambientales o la falta de una sintonización exhaustiva de hiperparámetros [3], [5], lo cual afecta directamente a la **eficiencia operativa, la**

economía de recursos computacionales y la confiabilidad de los sistemas inteligentes de posicionamiento, diagnóstico clínico y ciberseguridad en entornos de misión crítica [1], [3], [5].

■ Consecuencias o impacto

Esta situación genera consecuencias como la saturación del ancho de banda y la potencial falla de los controladores en redes definidas por software (SDN) ante ataques DDoS [1], el incremento en el riesgo de accidentes físicos y el desarrollo de estados depresivos en pacientes neurológicos debido a la incapacidad de predecir crisis de forma precisa [3], y errores de posicionamiento que comprometen la fiabilidad de la localización en entornos industriales o médicos complejos [5].

Asimismo, la alta redundancia en datos hiperespectrales [2] y el procesamiento aislado de tareas de clasificación y regresión [4] provocan un desperdicio de recursos computacionales, dificultando la transmisión eficiente de la información. Esta situación limita la capacidad de respuesta en tiempo real y la robustez de los sistemas inteligentes en dominios de misión crítica donde la precisión y la economía de recursos son fundamentales [1], [4], [5].

■ Actores involucrados

Los principales actores involucrados incluyen a los **administradores de red y especialistas en ciberseguridad** [1], quienes requieren herramientas precisas para proteger la disponibilidad de servicios en redes SDN. En el ámbito sanitario, destacan el **personal clínico, investigadores médicos y pacientes con trastornos neurológicos** [3], [4], como epilepsia o Alzheimer, quienes dependen de la eficiencia del algoritmo para la predicción de convulsiones y el diagnóstico de la severidad clínica.

Asimismo, se identifican como afectados a los **ingenieros de sistemas de posicionamiento y expertos en teledetección** [2], [5] en sectores de manufactura, minería y agricultura, los cuales emplean el procesamiento de señales e imágenes hiperespectrales para tareas de localización y clasificación de objetos en entornos complejos. Finalmente, el problema impacta a las **organizaciones tecnológicas** [1], [4] que desarrollan marcos de aprendizaje automático para la toma de decisiones automatizada en sistemas de misión crítica.

■ Variables o elementos clave

Los elementos clave que intervienen en este problema son la **precisión de clasificación** en la detección de ataques y diagnósticos clínicos [1], [3], la **latencia de detección** y el **overhead de procesamiento y comunicación** en sistemas de seguridad de red

en tiempo real [1], y la **Información Interpretable Multivariada (MII)** requerida para mitigar la redundancia en datos de alta dimensionalidad [2].

Asimismo, el rendimiento del algoritmo está definido por la **ganancia de división** (*split gain*) de las variables [2], las **dependencias secuenciales y complementarias** entre características [4], y métricas de error continuo como el **error cuadrático medio (MSE)**, el **error absoluto medio (MAE)** y la **raíz del error cuadrático medio (RMSE)** en tareas de regresión simultánea [4].

Finalmente, intervienen factores como la **robustez ante el ruido NLOS** [5], los **hiperparámetros del modelo** —incluyendo la tasa de aprendizaje (*eta*), la profundidad máxima y el ratio de submuestreo— [3], y la eficacia en el **manejo de valores atípicos** mediante métodos estadísticos y de agrupamiento [5].

■ Delimitación del problema

Esta investigación se delimita al análisis del algoritmo **eXtreme Gradient Boosting (XGBoost)** [1] y sus variantes técnicas, tales como el modelo de aprendizaje dual **DXGBA** [4] para la ejecución simultánea de tareas de clasificación y regresión, y el marco **Light Gradient Boosting Machine (LGBM)** [3] para el procesamiento de señales de alta velocidad. El estudio considera factores fundamentales como la optimización de hiperparámetros (tasa de aprendizaje, profundidad máxima y número de árboles) [3], la reducción de la redundancia en la Información Interpretable Multivariada (MII) [2], y la mejora de la eficiencia operativa mediante la reducción del tiempo de prueba y el *overhead* de procesamiento [4]. Asimismo, el alcance técnico se restringe al procesamiento de tipos de datos específicos que incluyen señales de electroencefalografía (EEG) [3], perfiles de tráfico SDN [1], imágenes hiperespectrales [2] y datos de Respuesta al Impulso del Canal (CIR) en entornos UWB [5].

Por el contrario, esta investigación excluye el análisis de arquitecturas de redes neuronales profundas que no operen como base de comparación directa, la exploración de fenómenos físicos de difracción de señales que no estén capturados en los datos digitales analizados [5] y la implementación de sistemas de seguridad en redes SDN con arquitecturas de múltiples controladores [1].

■ Vinculación con la sublínea de investigación

Este problema se enmarca dentro de la sublínea de investigación **Sistemas Inteligentes**, debido a su enfoque en la **concepción, optimización y despliegue de modelos predictivos avanzados** que permiten la toma de decisiones autónoma y precisa en entornos de alta complejidad algorítmica. La investigación se alinea con la necesidad de evolucionar las arquitecturas de aprendizaje supervisado, como **XGBoost**, para superar

limitaciones estructurales en el procesamiento de datos masivos y multidimensionales, garantizando la eficiencia operativa en sistemas críticos [1], [4].

La vinculación técnica se justifica mediante el desarrollo de **modelos predictivos robustos** capaces de capturar relaciones no lineales en señales de diversa naturaleza, tales como electroencefalogramas para la predicción de crisis convulsivas [3] o respuestas al impulso del canal en sistemas de posicionamiento UWB [5]. Asimismo, el estudio aborda la **optimización de algoritmos de aprendizaje automático** a través del ajuste fino de hiperparámetros y la reducción de la redundancia en la Información Interpretatable Multivariada (MII) [2], aspectos fundamentales para mejorar la capacidad de generalización del modelo.

Finalmente, la integración de marcos de **aprendizaje dual** para la resolución simultánea de problemas de clasificación y regresión [4], junto con el diseño de mecanismos de mitigación de amenazas en redes de nueva generación [1], refuerza la pertenencia a esta sublínea. Estos esfuerzos buscan equilibrar la **economía de recursos computacionales** con una alta precisión predictiva, satisfaciendo los estándares de los **Sistemas Inteligentes** modernos aplicados a la ciberseguridad, la salud y la industria 4.0 [5].

Formulación de Preguntas y Objetivos de Investigación

PREGUNTAS DE INVESTIGACIÓN (TABLA):

Tabla 5.3: Preguntas de Investigación según Nivel Taxonómico

Tipo de Pregunta	Pregunta de Investigación
Descriptiva	¿Cuál es el nivel de precisión técnica de XGBoost en la detección de ataques DDoS en redes SDN durante el ciclo 2026?
Aplicada	¿Cómo se puede optimizar la mitigación de ataques usando XGBoost para asegurar la disponibilidad del controlador SDN?
Experimental	¿Cuál es la diferencia en la tasa de error de XGBoost frente a Random Forest bajo condiciones SMOTETomek?

OBJETIVOS (GENERALES Y ESPECÍFICOS):

1. Nivel Descriptivo

Objetivo General: Caracterizar el rendimiento técnico de XGBoost en la detección de ataques DDoS en redes SDN mediante métricas de precisión durante el periodo 2026.

Objetivos Específicos:

- Determinar la tasa de precisión utilizando el dataset CICDDoS2019.
- Cuantificar la tasa de falsos positivos en entornos de tráfico SDN simulado.
- Documentar la latencia de respuesta del modelo ante flujos de tráfico sospechosos.

2. Nivel Aplicado

Objetivo General: Implementar un sistema de mitigación basado en XGBoost para optimizar la disponibilidad del controlador SDN en infraestructuras de red.

Objetivos Específicos:

- Diseñar un disparador de umbral adaptativo basado en predicciones de XGBoost.
- Integrar el modelo XGBoost en el plano de control de una red SDN simulada.
- Verificar la preservación del ancho de banda mediante pruebas de estrés controladas.

3. Nivel Experimental

Objetivo General: Evaluar la efectividad de XGBoost frente a Random Forest y SVM mediante un entorno controlado de preprocesamiento y balanceo de datos.

Objetivos Específicos:

- Aplicar la técnica SMOTETomek para el balanceo de clases en el dataset de entrenamiento.
- Ejecutar pruebas comparativas de tiempo de entrenamiento y predicción entre los tres modelos.
- Analizar la ganancia de información para validar la optimización de recursos.

VARIABLES DE ESTUDIO

Variables: Nivel Descriptivo

- **Variable Única:** Rendimiento técnico del algoritmo XGBoost (orientado a métricas de precisión y latencia).

Variables: Nivel Aplicado

- **Variable Independiente:** Sistema de mitigación basado en XGBoost.
- **Variable Dependiente:** Disponibilidad del controlador SDN (optimización de recursos).

Variables: Nivel Experimental

- **Variable Independiente:** Modelos de aprendizaje automático (XGBoost vs. Random Forest vs. SVM) y técnicas de balanceo (SMOTETomek).
- **Variable Dependiente:** Efectividad del modelo (tiempo de ejecución y ganancia de información).

JERARQUIZACIÓN Y CATEGORIZACIÓN

Tabla 5.4: Categorización de Fuentes Basada en las Preguntas de Investigación

Artículo (Nombre)	Jerarquía	Antecedentes	Estado Arte	Trabajos Rel.
Bandwidth control and XGBoost for SDN DDoS protection [1]	Alto	Identifica la saturación del controlador SDN como brecha crítica ante ataques volumétricos.	Implementa un disparador de umbral adaptativo que alcanza una precisión del 99.9 % en detección.	Introduce el uso de SMOTETomek para balancear datasets de tráfico masivo (CICD-DoS2019).
A trustworthy model for cyberattack detection using BES and SHAP [13]	Alto	Expone la falta de transparencia en los modelos IDS tradicionales de “caja negra”.	Propone la optimización metaheurística Bald Eagle Search (BES) para sintonizar XGBoost.	Realiza la comparativa técnica más reciente entre XGBoost y Random Forest bajo métricas de equidad.
A hybrid XGBoost-SVM ensemble for IoMT detection [14]	Alto	Analiza la vulnerabilidad de dispositivos médicos ante inyecciones de datos y suplantación (spoofing).	Desarrolla una estrategia de votación suave (soft-voting) que fusiona XGBoost con núcleos SVM.	Valida la robustez del modelo contra ataques Man-in-the-Middle en redes de salud inteligentes.
Enhanced ransomware detection using hybrid models [19]	Alto	Describe la ineficacia de los modelos estándar para detectar ataques de ransomware raros (minorías).	Logra una tasa de recuperación superior al minimizar los falsos negativos mediante análisis de sensibilidad.	Se integra con infraestructuras de Big Data para procesar vectores de ataque en tiempo real.

Artículo (Nombre)	Jerarquía	Antecedentes	Estado Arte	Trabajos Rel.
Gradient boosting-based simultaneous classification and regression [4]	Alto	Cita la ineficiencia de entrenar modelos aislados para tareas que dependen entre sí.	Presenta el marco DXGBA que utiliza una función de costo conjunta para reducir el tiempo de prueba.	Demuestra que el aprendizaje dual mejora la convergencia estadística en comparación con redes neuronales.
Explaining RF and XGBoost with Shallow Decision Trees [11]	Alto	Evalúa las métricas de interpretabilidad global propuestas por Molnar (2025) en modelos de ensamble.	Introduce el co-clustering de características para generar árboles sustitutos de alta fidelidad.	Compara la complejidad estructural (nodos y profundidad) entre XGBoost y Random Forest.
An XGBoost-Based Knowledge Tracing with Taylor expansion [18]	Medio	Se basa en los modelos FM y DKT para el seguimiento de habilidades cognitivas en estudiantes.	Optimiza la función objetivo de XGBoost mediante expansión de Taylor de segundo orden.	Logra un AUC de 0.9855, superando la eficiencia computacional de los modelos de Deep Learning.
Robust classification of UWB NLOS/-LOS using FCE-XGBoost [5]	Medio	Analiza el impacto del ruido ambiental y multipatía en señales de banda ultra-ancha (UWB).	Combina Evaluación Difusa (FCE) con XGBoost para clasificar condiciones de línea de vista.	Establece una latencia de inferencia de 0.0019 ms, crítica para el posicionamiento en interiores.
TimeBoost: Accelerating timing analysis engines using GPU [6]	Medio	Identifica el cuello de botella en el análisis de tiempos de circuitos VLSI usando métodos tradicionales.	Utiliza aceleración por GPU para ejecutar el ensamble de XGBoost sobre un millón de muestras.	Reporta una mejora de velocidad de 3.86x manteniendo una estabilidad superior a las redes ANN.
Predicting Bio-medical signals and seizures using LGBM and XGBoost [3]	Medio	Revisa el uso de PCA y filtros digitales para el preprocesamiento de señales de EEG de Bonn.	Compara variantes de Gradient Boosting, demostrando que XGBoost es superior en sensibilidad diagnóstica.	Define los parámetros óptimos (profundidad de árbol 7) para evitar el sobreajuste en datos médicos.

Artículo (Nombre)	Jerarquía	Antecedentes	Estado Arte	Trabajos Rel.
Video quality prediction under variable network conditions [16]	Medio	Investiga la degradación del Mean Opinion Score (MOS) por pérdida de paquetes en transmisiones.	Mapea métricas objetivas (VMAF/S-SIM) a escalas subjetivas usando regresión de gradiente.	Valida el rendimiento del algoritmo en entornos de red inestables con errores mínimos (RMSE 0.31).
Prediction of concrete labour productivity using XGBoost [17]	Medio	Analiza estudios previos de 2020-2023 que fallaron en predecir la productividad en muestras pequeñas.	Logra un coeficiente R2 de 0.998 mediante validación cruzada rigurosa de cinco pliegues.	Establece una jerarquía de algoritmos donde XGBoost supera a SVM en el manejo de variables no lineales.
Tool wear prediction in complex environments [15]	Medio	Revisa el desgaste de herramientas en manufactura bajo condiciones de lubricación variable.	Implementa un mecanismo iterativo de corrección de errores para predicciones de micro-desgaste.	Evalúa el compromiso técnico entre la tasa de aprendizaje y el tiempo de entrenamiento en planta.
Construction of Consumption Data Model Based on DNN-XGBoost [7]	Bajo	Basado en el desequilibrio de clases entre compradores reales y potenciales en e-commerce.	Integra redes neuronales profundas (DNN) para la extracción previa de características complejas.	Incrementa la precisión en un 17.5 % respecto a modelos de regresión logística tradicionales.
Hyperspectral band selection via interpretability from XGBoost [2]	Bajo	Identifica la redundancia excesiva de bandas en imágenes hiperespectrales satelitales.	Propone el método XGBS para evaluar la importancia de variables según la ganancia de división.	Mejora la clasificación multiclase reduciendo la dimensionalidad del dataset sin pérdida de información.
Optimization of big data resources: Industry 5.0 and ESG [8]	Bajo	Analiza el riesgo de fusiones empresariales bajo los nuevos estándares de Industria 5.0.	Utiliza Teoría Fundamentada para convertir datos cualitativos en vectores numéricos para XGBoost.	Clasifica factores de gobernanza ambiental con una precisión del 80 % en entornos de Big Data.

Artículo (Nombre)	Jerarquía	Antecedentes	Estado Arte	Trabajos Rel.
Text Recognition in the Automotive Field Based on XGBoost [10]	Bajo	Revisa las limitaciones de los sistemas OCR ante ruidos visuales y variabilidad de fuentes.	Implementa ingeniería de características mediante expresiones regulares y normalización Z-score.	Optimiza la estabilidad del reconocimiento de texto automotriz en condiciones de baja iluminación.
Valuation of innovation enterprises based on XGBoost-GA-BP [?]	Bajo	Identifica la dificultad de valorar empresas tecnológicas debido a distribuciones no normales.	Combina Algoritmos Genéticos (GA) con XGBoost para la selección óptima de indicadores.	Alcanza un coeficiente R2 superior al 97% en el análisis de 1558 observaciones financieras.
mlXGPR: a metabolic pathway prediction method [12]	Bajo	Analiza el problema de las etiquetas faltantes en la predicción de rutas metabólicas biológicas.	Implementa clasificación multi-etiqueta encadenada para capturar correlaciones enzimáticas.	Supera a los modelos mlLGPR y triUMPF en términos de Hamming Loss y precisión biológica.
Retraction Note: Improved fake news detection using hybrid models [20]	Bajo	Basado inicialmente en la detección de noticias falsas mediante RoBERTa y XGBoost.	Fuente Retractiva: Inconsistencias graves en el proceso de revisión y referencias técnicas.	Carece de validez científica para sustentar el desarrollo de nuevas arquitecturas de software.

Referencias bibliográficas

- [1] H. A. Alamri and V. Thayananthan, “Bandwidth control mechanism and extreme gradient boosting algorithm for protecting software-defined networks against ddos attacks,” *IEEE Access*, vol. 8, p. 194269–194288, 2020. [Online]. Available: <http://dx.doi.org/10.1109/ACCESS.2020.3033942>
- [2] X. Shang, C. Cui, X. Sun, X. Wang, and J. Zhang, “Classification task-driven hyperspectral band selection via interpretability from xgboost,” *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, vol. 18, p. 13733–13754, 2025. [Online]. Available: <http://dx.doi.org/10.1109/JSTARS.2025.3572278>
- [3] B. Kapoor and B. Nagpal, “Gradient boosting for predicting the relation between bio-medical signals and seizures using lgbm and xgboost,” *Journal of Mobile Multimedia*, p. 359–390, Mar. 2024. [Online]. Available: <http://dx.doi.org/10.13052/jmm1550-4646.2025>
- [4] R. Alwanin, O. Bchir, and M. M. B. Ismail, “Gradient boosting-based simultaneous classification and regression approach,” *IEEE Access*, vol. 13, p. 98557–98573, 2025. [Online]. Available: <http://dx.doi.org/10.1109/ACCESS.2025.3576086>
- [5] S. Wang and N. S. Ahmad, “Robust classification of uwb nlos/los using combined fce and xgboost algorithms,” *IEEE Access*, vol. 12, p. 151030–151045, 2024. [Online]. Available: <http://dx.doi.org/10.1109/ACCESS.2024.3480236>
- [6] A. Vagenas, D. Garyfallou, N. Evmorfopoulos, and G. Stamoulis, “Timeboost: Accelerating timing analysis engines using xgboost,” *AEU - International Journal of Electronics and Communications*, vol. 200, p. 155870, Oct. 2025. [Online]. Available: <http://dx.doi.org/10.1016/j.aeue.2025.155870>
- [7] C. Du, “Construction of consumption data optimization model based on xgboost algorithm,” *Procedia Computer Science*, vol. 262, p. 278–286, 2025. [Online]. Available: <http://dx.doi.org/10.1016/j.procs.2025.05.054>
- [8] Q. Su, L. Chen, and L. Qian, “Optimization of big data analysis resources supported by xgboost algorithm: Comprehensive analysis of industry 5.0 and esg performance,” *Measurement: Sensors*, vol. 36, p. 101310, Dec. 2024. [Online]. Available: <http://dx.doi.org/10.1016/j.measen.2024.101310>
- [9] S. S. Betgeri, M. Shukla, D. Kumar, S. B. Khan, M. A. Khan, and N. A. Alkhaldi, “Enhancing seizure detection with hybrid xgboost and recurrent neural networks,” *Neuroscience Informatics*, vol. 5, no. 2, p. 100206, 2025. [Online]. Available: <http://dx.doi.org/10.1016/j.neuri.2025.100206>
- [10] Y. Zhao, M. Zhang, F. Zhang, and J. Yang, *Research on Text Recognition in the Automotive Field Based on XGBoost and Feature Engineering*. Springer Nature Singapore, 2026, p. 64–73. [Online]. Available: http://dx.doi.org/10.1007/978-981-95-6946-5_7

- [11] R. G. Pensa, A. Crombach, S. Peignier, and C. Rigotti, "Explaining random forest and xgboost with shallow decision trees by co-clustering feature importance," *Machine Learning*, vol. 114, no. 12, Nov. 2025. [Online]. Available: <http://dx.doi.org/10.1007/s10994-025-06932-9>
- [12] H. Joe and H.-G. Kim, "Multi-label classification with xgboost for metabolic pathway prediction," *BMC Bioinformatics*, vol. 25, no. 1, Feb. 2024. [Online]. Available: <http://dx.doi.org/10.1186/s12859-024-05666-0>
- [13] S. Kundu, R. P. Chaturvedi, A. Mishra, A. Agrawal, S. M. Aldossary, M. Ayadi, K. B. Adem, and A. Hashmi, "A trustworthy cybersecurity model for transparent cyberattack detection using bald eagle search tuned xgboost and explainable ai," *Journal of Cloud Computing*, vol. 15, no. 1, Mar. 2026. [Online]. Available: <http://dx.doi.org/10.1186/s13677-026-00878-6>
- [14] M. Abdelhaq, S. Palanisamy, M. Gopinath, V. G. S. Manasa, M. A. Ram, and S. K. MD, "A hybrid xgboost-svm ensemble framework for robust cyber-attack detection in the internet of medical things (iomt)," *Scientific Reports*, vol. 16, no. 1, Jan. 2026. [Online]. Available: <http://dx.doi.org/10.1038/s41598-026-37832-0>
- [15] O. Almomani, B. Venkatesh, S. P. Chaudhary, A. Mishra, S. Sujai, S. Juneja, P. Pradhan, S. P. Venkatesan, A. Bhowmik, and Y. Tamene, "Intelligent tool wear monitoring using xgboost, svr, and dnn models in nmql environment," *Scientific Reports*, vol. 16, no. 1, Feb. 2026. [Online]. Available: <http://dx.doi.org/10.1038/s41598-026-40968-8>
- [16] J. Frnda, J. Rozhon, M. Uhrina, J. Bienik, and M. Voznak, "Video quality prediction and classification using xgboost under variable encoding and network conditions," *Scientific Reports*, Apr. 2026. [Online]. Available: <http://dx.doi.org/10.1038/s41598-026-47932-6>
- [17] A. Hassoon, F. E. M. Ghazali, and T. A. Khaleel, "Application of xgboost and artificial neural networks in predicting housing project productivity," *Discover Artificial Intelligence*, vol. 6, no. 1, Dec. 2025. [Online]. Available: <http://dx.doi.org/10.1007/s44163-025-00658-2>
- [18] W. Su, F. Jiang, C. Shi, D. Wu, L. Liu, S. Li, Y. Yuan, and J. Shi, "An xgboost-based knowledge tracing model," *International Journal of Computational Intelligence Systems*, vol. 16, no. 1, Feb. 2023. [Online]. Available: <http://dx.doi.org/10.1007/s44196-023-00192-y>
- [19] K. Zhang, Y. Wang, U. A. Bhatti, Y. Zhou, and M. Jin, "Enhanced ransomware attacks detection using feature selection, sensitivity analysis, and optimized hybrid model," *Journal of Big Data*, vol. 12, no. 1, Nov. 2025. [Online]. Available: <http://dx.doi.org/10.1186/s40537-025-01289-1>
- [20] C. Shen, L. Xiang, and W. Wang, "Valuation of science and technology innovation enterprises based on xgboost-ga-bp neural network model," *Scientific Reports*, vol. 15, no. 1, Aug. 2025. [Online]. Available: <http://dx.doi.org/10.1038/s41598-025-15282-4>