

Fundamentos de Inteligencia Artificial Clásica: Técnicas, Métodos y Aplicaciones Antes de la IA Generativa

Luis Chamba-Eras

Editor

2026

Índice general

I	Introducción y Fundamentos	1
II	Aprendizaje Estadístico y Modelos de Clasificación	2
10.	Ventajas Arquitectónicas y Algorítmicas de XGBoost en Problemas Complejos de Clasificación	3
10.1.	Introducción	3
10.2.	Fundamentos Teóricos	4
10.3.	Metodología y Análisis de la Literatura	8
10.4.	Análisis de Ventajas Competitivas en Clasificación Compleja	10
10.5.	Evaluación de Métricas de Rendimiento y Comportamiento Algorítmico	11
10.5.1.	Análisis de Sensibilidad (Recall) ante Eventos Críticos Minoritarios	11
10.5.2.	Optimización del Balance F1-Score en Datasets Altamente Imbalanceados	12
10.5.3.	Comportamiento de la Curva AUC-ROC bajo Escenarios de Ruido y Pérdida de Canales	12
10.5.4.	Métricas de Ganancia y Cobertura en la Interpretación Estructural del Modelo	13
10.6.	Conclusiones	13

Parte I

Introducción y Fundamentos

Parte II

Aprendizaje Estadístico y Modelos de Clasificación

Capítulo 10

Ventajas Arquitectónicas y Algorítmicas de XGBoost en Problemas Complejos de Clasificación

Autor: Cael Alejandro Soto Castillo (cael.soto@unl.edu.ec)
Técnica asignada: XGBoost

10.1. Introducción

Contexto general del problema

La clasificación automatizada en entornos industriales y científicos contemporáneos se enfrenta a hiper-superficies de datos multivariados caracterizadas por una alta dimensionalidad y un desbalance estructural intrínseco que desafía la capacidad de generalización de los modelos estocásticos convencionales. Estas topologías complejas suelen presentar la denominada maldición de la dimensionalidad y niveles críticos de ruido, donde los métodos de clasificación tradicionales, como las regresiones lineales o los árboles de decisión únicos, fallan al no capturar las relaciones no lineales de orden superior y sucumbir ante el sobreajuste en el hiperespacio de características [1–3]. Ante este escenario, la arquitectura de eXtreme Gradient Boosting (XGBoost) emerge como la solución estándar en ingeniería, fundamentada en un paradigma de aprendizaje aditivo donde cada estimador secuencial corrige iterativamente los errores residuales mediante una optimización basada en gradientes de segundo orden que emplea la expansión de Taylor para una convergencia estocástica más precisa [4–6]. A diferencia de los modelos ortodoxos, XGBoost integra una regularización estructural rigurosa (ℓ_1 y ℓ_2) en su función objetivo para penalizar la complejidad del modelo, aprovechando además una infraestructura de computación paralela y el uso de *weighted quantile sketches* que permiten procesar eficientemente grandes volúmenes de datos masivos [7–9].

Situación actual basada en evidencia

El contraste empírico en la literatura científica reciente posiciona a XGBoost como un referente de alto rendimiento, superando consistentemente a algoritmos como Support Vector Machines (SVM) y Redes Neuronales Profundas en precisión predictiva y velocidad de ejecución, siendo reportado como hasta diez veces más rápido que las implementaciones de Gradient Boosting tradicionales [4, 9, 10]. Una de sus ventajas algorítmicas más disruptivas es el manejo nativo de datos faltantes, el cual utiliza direcciones de división predeterminadas en los nodos para preservar la estructura inherente de la señal sin recurrir a sesgos de imputación externa [11, 12].

Asimismo, su robustez ante el desequilibrio de clases se ve potenciada por la capacidad de ajustar pesos específicos o integrar funciones de pérdida personalizadas, como la *focal loss*, permitiendo una sensibilidad superior en la detección de eventos minoritarios pero críticos en dominios de ciberseguridad y diagnóstico médico [6, 13, 14]. Finalmente, la implementación de mecanismos de importancia de características basados en ganancia (*Gain*) y cobertura (*Cover*) proporciona una interpretabilidad analítica que facilita la reducción de dimensionalidad y la eliminación de redundancia en sistemas de alta fidelidad [15–17].

Objetivo y estructura del capítulo

El propósito fundamental de este capítulo es auditar y sistematizar las ventajas operativas y metodológicas que ofrece el algoritmo XGBoost en la resolución de problemas de clasificación compleja en ingeniería. A través de un análisis crítico fundamentado en el estado del arte contemporáneo, se busca responder de forma concluyente a las interrogantes sobre su superioridad en eficiencia computacional, robustez matemática ante señales degradadas y adaptabilidad en escenarios de desbalance extremo. Para cumplir con este objetivo, el documento se estructura partiendo de una rigurosa matriz analítica de la literatura científica reciente, seguida de un desglose profundo de sus ventajas competitivas clave bajo criterios de escalabilidad y regularización intrínseca, concluyendo con una síntesis técnica sobre la viabilidad de su despliegue en entornos industriales de alta disponibilidad.

10.2. Fundamentos Teóricos

Desglose de la Función Objetivo Regularizada

La fundamentación analítica de XGBoost se articula a través de una función objetivo regularizada diseñada para minimizar el riesgo estructural mediante un equilibrio formal entre la precisión del ajuste y la parsimonia del modelo [8, 9, 18, 19]. En la optimización del ensamble, la función objetivo global en la iteración t se define formalmente a través de la siguiente expresión matemática:

$$\mathcal{L}^{(t)} = \sum_{i=1}^n l\left(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)\right) + \Omega(f_t) \quad (10.1)$$

En esta formulación, el término l representa una función de pérdida diferenciable y convexa (como la pérdida logística o la entropía cruzada para clasificación) que cuantifica el error residual entre el valor real y_i y la predicción acumulada [8, 9, 15, 20]. Bajo un esquema de aprendizaje aditivo, el modelo no se reentrena globalmente, sino que en cada iteración t se añade un nuevo estimador débil $f_t(x_i)$ cuya misión es corregir los errores residuales del ensamble previo $\hat{y}_i^{(t-1)}$ [7, 9, 19, 20]. La robustez de esta arquitectura frente al sobreajuste reside en la incorporación de una penalización estricta sobre la complejidad del árbol, expresada mediante el término matemático:

$$\Omega(f_t) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2 \quad (10.2)$$

Esta penalización introduce dos hiperparámetros críticos para el control operativo: en primer lugar, el coeficiente gamma (γ) actúa como el umbral de ganancia mínima necesario para permitir una división adicional del nodo, controlando así el número total de hojas T para incentivar la

poda automática (*pruning*) [2, 6, 10–12]; en segundo lugar, el coeficiente lambda (λ) impone una regularización de tipo L_2 sobre el vector de pesos de los nodos w , suavizando las salidas del modelo para garantizar el mapeo de patrones generales en lugar de ruido estocástico [9, 11, 15, 21]. Este control dual mitiga de forma eficiente la vulnerabilidad al sobreajuste en espacios de características caracterizados por una alta dimensionalidad y desbalance estructural [6, 9, 11, 22].

Optimización mediante la Expansión de Taylor de Segundo Orden

Para superar las limitaciones de los algoritmos de *Gradient Boosting* tradicionales que solo emplean información de primer nivel, XGBoost implementa una aproximación de Taylor de segundo orden que transforma la función objetivo en una formulación cuadrática simplificada [4, 13, 23]. Mediante esta expansión, el objetivo en el paso t puede aproximarse de la siguiente manera:

$$\mathcal{L}^{(t)} \approx \sum_{i=1}^n \left[l(y_i, \hat{y}_i^{(t-1)}) + g_i f_t(x_i) + \frac{1}{2} h_i f_t^2(x_i) \right] + \Omega(f_t) \quad (10.3)$$

Al remover los términos constantes que no dependen de $f_t(x_i)$, el algoritmo extrae de forma iterativa los componentes de optimización para cada muestra:

$$g_i = \frac{\partial l(y_i, \hat{y}_i^{(t-1)})}{\partial \hat{y}_i^{(t-1)}} \quad \text{y} \quad h_i = \frac{\partial^2 l(y_i, \hat{y}_i^{(t-1)})}{\partial (\hat{y}_i^{(t-1)})^2} \quad (10.4)$$

Donde g_i representa el gradiente de primer orden y h_i denota el hessiano de segundo orden. Esta aproximación permite al optimizador identificar no solo la dirección del descenso, sino también la curvatura exacta de la superficie de pérdida [1, 5, 6, 12]. Esta sofisticación algorítmica es fundamental para manejar funciones de pérdida personalizadas genéricas, permitiendo la integración nativa de mecanismos como la *Focal Loss* para abordar el desequilibrio de clases extremo en entornos industriales y médicos [6, 9, 14, 23]. La eficiencia computacional derivada de esta aproximación cuadrática simplifica el cálculo analítico de los pesos de las hojas y facilita el uso de técnicas de búsqueda de divisiones basadas en histogramas y *weighted quantile sketches*, optimizando el rendimiento en infraestructuras de cómputo paralelo [5, 7, 9].

Mecanismos de División de Nodos y Búsqueda de Split

La arquitectura recursiva de XGBoost construye el ensamble de árboles mediante un proceso de optimización topológica que busca identificar los puntos de corte óptimos en el hiperespacio de características para maximizar la reducción del error residual [2, 4, 15, 22]. Para lograr esta eficiencia en entornos de alta disponibilidad, el algoritmo implementa tanto el *Exact Greedy Algorithm*, que enumera exhaustivamente todas las divisiones potenciales en todas las dimensiones, como algoritmos aproximados basados en histogramas y *weighted quantile sketches* que agrupan los valores de las características en *bins* discretos para acelerar la computación en datasets masivos [5, 7, 19, 25]. La métrica decisoria fundamental para ejecutar una ramificación es la Ganancia (*Gain*), la cual se deriva analíticamente de la aproximación de Taylor de segundo orden y la regularización estructural, formulándose matemáticamente de la siguiente manera:




Figura 10.1: Mecanismo de aprendizaje aditivo secuencial en XGBoost. Se ilustra cómo el modelo entrena árboles de forma sucesiva, donde cada nuevo árbol se enfoca exclusivamente en corregir los errores (residuos) del anterior, combinando finalmente el conocimiento de todos en una predicción unificación. Fuente: Tomado de [24].

$$Gain = \frac{1}{2} \left[\frac{\left(\sum_{i \in I_L} g_i \right)^2}{\sum_{i \in I_L} h_i + \lambda} + \frac{\left(\sum_{i \in I_R} g_i \right)^2}{\sum_{i \in I_R} h_i + \lambda} - \frac{\left(\sum_{i \in I} g_i \right)^2}{\sum_{i \in I} h_i + \lambda} \right] - \gamma \quad (10.5)$$

En esta expresión, el primer término fraccionario representa el puntaje de estructura del nodo hijo izquierdo (I_L) tras la división, el segundo término cuantifica el puntaje del nodo hijo derecho (I_R), y el tercer término resta el puntaje de estructura del nodo padre (I) antes de segmentar los datos [10–12, 20]. Cada fracción integra la suma de los gradientes g_i al cuadrado, normalizada por la suma de los hessianos h_i y el parámetro de regularización λ , lo que garantiza que la división no solo considere la dirección del error, sino también la curvatura de la función de pérdida y la estabilidad de los pesos de las hojas [6, 9, 13, 18].

Finalmente, la sustracción del hiperparámetro gamma (γ) actúa como un mecanismo de poda intrínseco (*post-pruning*); si la ganancia calculada es menor que γ , el algoritmo inhibe la división del nodo al considerar que la mejora en la fidelidad no justifica el incremento en la complejidad estructural del modelo, protegiendo así al sistema contra la captura de ruido estocástico [2, 5, 8, 12, 19].




Figura 10.2: Visualización del balance entre el ajuste y la complejidad en un espacio de características. Los puntos (X) representan las muestras de datos, e ilustran el riesgo de usar un modelo demasiado simple, uno sobreajustado que memoriza el ruido, y el balance óptimo que busca XGBoost mediante regularización. Fuente: Tomado de [26].

Síntesis Teórica Frente a la Clasificación Compleja

La robustez arquitectónica de XGBoost en problemas complejos de clasificación emana de la convergencia sinérgica entre su función objetivo regularizada, la optimización mediante la expansión de Taylor y el criterio de ganancia estructural, proporcionando una solución de ingeniería que trasciende las limitaciones del aprendizaje estadístico tradicional [3, 21, 27, 28]. Esta estructura matemática le permite optimizar problemas de clasificación en entornos industriales y científicos mediante un paradigma de aprendizaje federado y aditivo que es intrínsecamente inmune al sobreajuste, gracias al control dual ejercido por λ sobre la magnitud de los pesos y por γ sobre la profundidad del árbol [1, 4, 6, 29, 30].

La integración de la información de segundo orden (hessianos) no solo acelera la convergencia estocástica, sino que permite al modelo ser altamente tolerante al ruido y manejar nativamente datos faltantes y dispersos sin recurrir a sesgos de imputación externa, lo cual es crítico en dominios de ciberseguridad, diagnóstico médico y análisis espectral [11, 15, 25, 31, 32]. Además, su capacidad para incorporar funciones de pérdida personalizadas, como la *focal loss*, otorga a XGBoost una ventaja competitiva superior en la clasificación de datos desbalanceados, permitiendo una sensibilidad analítica en la detección de eventos minoritarios que modelos como SVM o redes neuronales profundas a menudo fallan en capturar sin un costo computacional prohibitivo [5, 8, 13, 14, 23].

En consecuencia, la implementación de mecanismos de importancia de características basados en ganancia y cobertura dota al modelo de una interpretabilidad de alta fidelidad, facilitando la eliminación de redundancias y la toma de decisiones basada en evidencia en sistemas de misión crítica [2, 10, 15, 16, 22, 33, 34]. Esta versatilidad técnica consolida a XGBoost como el estándar

de oro en ingeniería de aprendizaje automático para la resolución de hiper-superficies de datos multivariados con alta dimensionalidad [7, 9, 12, 17–20, 35].

10.3. Metodología y Análisis de la Literatura

Estrategia de Selección y Criterios de Inclusión

La metodología empleada para auditar las ventajas algorítmicas de XGBoost se fundamenta en un mapeo sistemático de la literatura científica de vanguardia, diseñado para identificar patrones de rendimiento en topologías de datos de alta complejidad. El proceso de selección se rigió por criterios técnicos estrictos, priorizando investigaciones que demostraran una mejora significativa en la capacidad de generalización del modelo frente a la clasificación convencional [8, 9, 15, 19, 20]. Se analizaron exhaustivamente factores de rendimiento estructural relacionados con la minimización del riesgo empírico y la eficiencia en infraestructuras de cómputo paralelo, elementos críticos para el procesamiento de datasets masivos en tiempo real [5, 7, 12, 25, 33].

Un eje central de la revisión fue el manejo nativo del desbalance de clases, evaluando cómo la integración de funciones de pérdida personalizadas y técnicas de remuestreo intrínseco permiten una sensibilidad superior en la detección de eventos minoritarios [2, 4, 6, 13, 14, 23]. Asimismo, se auditó la robustez del algoritmo ante el ruido y la ausencia de datos, validando su capacidad para inferir direcciones de división óptimas sin recurrir a sesgos de imputación externa [11, 21, 30, 32, 34]. Finalmente, la revisión integró estudios sobre arquitecturas híbridas y aprendizaje federado, consolidando un marco conceptual que abarca desde la optimización metaheurística hasta aplicaciones críticas en ciberseguridad, diagnóstico médico y sistemas industriales de alta disponibilidad [1, 3, 10, 17, 18, 22, 27–29, 31, 35]. Esta auditoría bibliográfica integral garantiza que el sustento teórico de este capítulo refleje el estado del arte en ingeniería de aprendizaje automático.

Matriz de Análisis Bibliográfico de la Literatura

Con el propósito de estructurar los hallazgos y contrastar los diferentes enfoques metodológicos identificados en el estado del arte, se presenta a continuación la matriz analítica detallada. Esta estructura distribuye dinámicamente el contenido para garantizar un flujo de lectura continuo entre las páginas del documento.

Ref.	Enfoque de Ingeniería / Aplicación	Aporte Específico en Clasificación y Rendimiento
[31]	Reconocimiento de texto en el sector automotriz.	Implementa un marco de ingeniería de características basado en XGBoost para procesar datos heterogéneos, optimizando significativamente la precisión y la estabilidad frente a modelos lineales convencionales.
[4]	Seguridad en Internet de las Cosas Médicas (IoMT).	Propone un ensamble de votación suave que integra XGBoost y SVM, superando a las redes neuronales profundas en entornos de recursos limitados con una precisión diagnóstica del 94.21 %.
[1]	Aprendizaje dual para clasificación y regresión simultánea.	Desarrolla la arquitectura DXGBA que utiliza árboles compartidos y una función objetivo conjunta, reduciendo la redundancia computacional en un 81.9 % en tareas de monitoreo industrial.

Tabla 10.1 – Continúa de la página anterior

Ref.	Enfoque de Ingeniería / Aplicación	Aporte Específico en Clasificación y Rendimiento
[32]	Computación granular multi-distancia (GXG-Boost).	Introduce la granularización de características para mitigar el sobreajuste en escenarios de muestras pequeñas, expandiendo la dimensionalidad para capturar estructuras internas no lineales.
[16]	Clasificación de formas de onda en redes eléctricas reales.	Diseña un modelo en cascada que descompone tareas multiclase en decisiones binarias, logrando una velocidad de entrenamiento 109 veces superior a modelos LSTM y 19 veces a CNN.
[6]	Aprendizaje federado con desequilibrio de clases.	Introduce la pérdida focal sinérgica para ajustar dinámicamente los pesos de las clases minoritarias en infraestructuras distribuidas, mejorando la privacidad.
[11]	Detección del estado ocular mediante señales EEG.	Demuestra la robustez nativa de XGBoost ante la pérdida de canales (hasta un 20 %) sin imputación, manteniendo un rendimiento estable mediante direcciones de división aprendidas.
[35]	Predicción de crisis epilépticas en señales EEG.	Analiza la relación entre señales biomédicas y convulsiones, utilizando XGBoost para identificar biomarcadores críticos mediante análisis de correlación y alcanzando una sensibilidad superior al 90 % en señales de EEG.
[5]	Detección de intrusiones mediante optimización BES.	Integra el algoritmo <i>Bald Eagle Search</i> para el ajuste fino de hiperparámetros, logrando una precisión récord del 99.7 % y garantizando interpretabilidad total mediante valores SHAP.
[18]	Clasificación de embarcaciones navales mediante AIS.	Emplea una variante híbrida del algoritmo <i>Sine Cosine</i> para optimizar la estructura del ensamble, alcanzando una precisión de clasificación del 99.72 % en escenarios marítimos complejos.
[17]	Evaluación de la calidad de video en sistemas IPTV.	Desarrolla un modelo de referencia reducida que utiliza XGBoost para clasificar el MOS percibido, obteniendo un <i>F1-score</i> de 0.92 bajo condiciones de red y codificación variables.
[14]	Diagnóstico psiquiátrico con desbalance extremo.	Propone una función de pérdida personalizada que combina <i>Focal Loss</i> y penalización de confianza, elevando el <i>recall</i> de clases críticas del 0.73 al 1.00 en la detección de trastornos.
[3]	Explicabilidad mediante co-clustering (XCCSHAP).	Mejora la transparencia de XGBoost construyendo árboles de decisión superficiales como modelos subrogados, optimizando el equilibrio entre fidelidad predictiva y comprensibilidad humana.
[22]	Selección de bandas en imágenes hiperespectrales (XGBS).	Extrae información interpretable (<i>split gain</i> y dependencias) de la estructura del árbol para identificar bandas con alta interdependencia y baja redundancia espectral.
[12]	Reconocimiento de señales NLOS en posicionamiento UWB.	Combina Evaluación Difusa (FCE) con XGBoost para filtrar anomalías y clasificar trayectorias de señal, logrando una robustez superior en diversos entornos interiores.

Tabla 10.1 – Continúa de la página anterior

Ref.	Enfoque de Ingeniería / Aplicación	Aporte Específico en Clasificación y Rendimiento
[9]	Clasificación de niveles de hipertensión clínica.	Valida que XGBoost es hasta diez veces más rápido que implementaciones de <i>Gradient Boosting</i> estándar, manteniendo una alta capacidad de generalización en registros médicos masivos.
[33]	Clasificación de dispositivos IoT mediante VAE-XGBoost.	Integra <i>Autoencoders</i> Variacionales para la extracción de características latentes, optimizando el clasificador mediante recorte de gradientes y poda estructural.
[15]	Análisis de metales pesados mediante espectroscopía LIBS.	Utiliza XGBoost para la selección <i>backward</i> de características, eliminando el 98 % de la redundancia espectral y mejorando la estabilidad de la red neuronal MLP integrada.
[13]	Clasificación de coberturas terrestres en teledetección.	Define un criterio de margen extendido para evaluar la incertidumbre en datos imbalanceados, demostrando un margen de confianza un 46 % superior al de <i>Random Forest</i> .
[34]	Optimización de análisis de tiempos en VLSI (Time-Boost).	Implementa clasificadores acelerados por GPU para seleccionar métodos de análisis óptimos, logrando una mejora en el tiempo de ejecución de hasta 3.86x en el diseño de circuitos.
[8]	Detección de sitios de phishing.	Optimiza los hiperparámetros mediante <i>Particle Swarm Optimization</i> (PSO), incrementando la estabilidad del modelo frente a ataques de ingeniería social en el hiperespacio web.
[7]	Clasificación de tráfico DDoS.	Evalúa el impacto crítico del preprocesamiento y la selección de características en la detección de anomalías de red, validando la superioridad de XGBoost en métricas de precisión y F1.
[10]	Evaluación del desempeño ESG en Industria 5.0.	Aplica XGBoost para modelar la sostenibilidad empresarial, identificando factores clave en grandes volúmenes de datos industriales con alta robustez y generalización.
[23]	Clasificación binaria en datos con etiquetas sesgadas.	Proporciona las bases teóricas de la aproximación de segundo orden para funciones de pérdida personalizadas, facilitando la vectorización y eficiencia del modelo.

Tabla 10.1: Matriz de análisis bibliográfico sobre el rendimiento y aplicaciones de XGBoost en la resolución de problemas de clasificación compleja en ingeniería.

10.4. Análisis de Ventajas Competitivas en Clasificación Compleja

La eficiencia operativa de XGBoost constituye una de sus mayores fortalezas en entornos de ingeniería, logrando velocidades de entrenamiento y ejecución que superan por órdenes de magnitud a los modelos de aprendizaje profundo secuenciales y convolucionales [9, 16]. Evidencia empírica demuestra que esta arquitectura puede completar procesos de instrucción hasta 109 veces más rápido que redes LSTM y 19 veces más rápido que modelos CNN, manteniendo una huella de memoria reducida que facilita su despliegue en sistemas de recursos limitados sin requerir obligatoriamente aceleración por GPU [4, 16, 34].

Esta celeridad computacional se deriva de una infraestructura de procesamiento paralelo y el uso de lógicas como los *weighted quantile sketches*, que permiten la gestión de matrices de datos masivas con una escalabilidad superior a las implementaciones tradicionales de *Gradient Boosting* [5, 7, 31]. A diferencia de las redes neuronales que exigen cálculos matriciales intensivos y retropropagación temporal, la lógica de ensamble aditivo de XGBoost optimiza la utilización de recursos de CPU, consolidándose como la opción predilecta para aplicaciones industriales de tiempo real donde la latencia es un factor restrictivo [16, 19, 25, 34].

En términos de integridad analítica, XGBoost ofrece una robustez matemática intrínseca para navegar hiperespacios de características ruidosos y fragmentados, destacando su capacidad nativa para el tratamiento de datos faltantes sin recurrir a la imputación externa [11, 13]. Mediante el aprendizaje de direcciones de división predeterminadas en cada nodo, el algoritmo preserva la estructura de la señal original incluso bajo pérdidas críticas de hasta un 20 % de la información, evitando sesgos artificiales introducidos por procesos de relleno estadístico [11, 12].

El control del sobreajuste se garantiza a través de una función objetivo que integra penalizaciones estructurales L1 y L2, junto con estrategias de submuestreo de columnas y filas que diluyen la varianza estocástica en datasets de alta dimensionalidad [5, 13, 15, 20]. Esta arquitectura se ve potenciada por la expansión de Taylor de segundo orden, la cual proporciona una convergencia más precisa al capturar la curvatura de la superficie de pérdida mediante estadísticos hessianos, permitiendo que el sistema ignore fluctuaciones menores y se concentre en patrones de generalización sólidos en topologías multivariadas complejas [5, 6, 9, 21].

La versatilidad algorítmica para ajustarse a distribuciones de datos heterogéneas representa la tercera ventaja competitiva fundamental, especialmente mediante la integración de funciones de pérdida personalizadas para resolver desequilibrios de clase extremos [6, 14, 23]. La implementación de la *Synergetic Focal Loss* permite al modelo mitigar el sesgo hacia las clases mayoritarias, reduciendo dinámicamente el peso de las muestras correctamente clasificadas y priorizando el aprendizaje sobre eventos minoritarios pero críticos en dominios como la ciberseguridad o el diagnóstico médico [4, 6, 14].

A diferencia de los clasificadores estándar que priorizan la precisión global a través de criterios deficientes, XGBoost facilita una sensibilidad analítica superior que eleva las métricas de *Recall* y puntuación F1 en escenarios de detección de intrusiones o fallos raros [4–6, 13]. Esta adaptabilidad se extiende a su capacidad para operar en esquemas de aprendizaje federado y distribuido, donde la optimización de hiperparámetros locales se sincroniza con la arquitectura global para garantizar una convergencia estable sin comprometer la privacidad ni la fidelidad predictiva en datasets no-IID [1, 3, 6, 27, 30, 32].

10.5. Evaluación de Métricas de Rendimiento y Comportamiento Algorítmico

La validación de la eficacia de una arquitectura basada en XGBoost exige un análisis multidimensional que trascienda la métrica de precisión convencional, la cual suele resultar engañosa en topologías de datos caracterizadas por desbalances estructurales o niveles críticos de ruido [4, 20, 23]. La fundamentación de este proceso evaluativo reside en la capacidad del algoritmo para minimizar de forma simultánea el error de entrenamiento y el riesgo estructural, integrando estadísticos de segundo orden que guían la convergencia hacia fronteras de decisión óptimas [5, 9, 19, 21]. A través del monitoreo de indicadores de fidelidad como la sensibilidad, la puntuación F1 y el área bajo la curva ROC, es posible auditar el comportamiento del ensamble aditivo frente a la varianza estocástica del entorno industrial [7, 13, 14, 16]. Esta sección profundiza en el comportamiento empírico del modelo, desglosando cómo las innovaciones en la función objetivo y la regularización matemática se traducen en una superioridad competitiva para la resolución de problemas de clasificación de alta complejidad [1, 6, 15, 31].

10.5.1. Análisis de Sensibilidad (Recall) ante Eventos Críticos Minoritarios

La maximización de la sensibilidad o exhaustividad (*Recall*) en XGBoost constituye un imperativo técnico en dominios donde la omisión de un evento positivo conlleva riesgos catastróficos, como la detección de intrusiones en Internet de las Cosas Médicas (IoMT) o el diagnóstico de trastornos

psiquiátricos raros [4, 14]. A diferencia de los modelos lineales que sucumben al sesgo de la clase mayoritaria, XGBoost implementa funciones de pérdida adaptativas y técnicas de ponderación de instancias (`scale_pos_weight`) que permiten al optimizador de segundo orden concentrar la energía de aprendizaje en las muestras de difícil clasificación [6, 13, 23]. En entornos de ciberseguridad, se ha demostrado que esta arquitectura alcanza un *Recall* superior al 97.99 %, logrando identificar patrones de ataque sutiles —como inyección de datos o *spoofing*— que otros sistemas de detección de anomalías suelen ignorar para preservar una precisión global artificialmente alta [4, 5, 7, 29].

La superioridad analítica en la detección de eventos críticos se ve reforzada por la capacidad del algoritmo para realizar un ajuste de umbral probabilístico (*threshold shifting*) basado en la maximización de la métrica G-mean y el coeficiente de correlación de Matthews [8, 11, 28]. En tareas de detección de fraude financiero y monitorización biométrica, la calibración de umbrales óptimos —frecuentemente situados en valores como 0.3 o 0.245— permite elevar el *Recall* desde niveles deficientes del 73 % hasta un 100 % en clases de alta prioridad clínica, como el trastorno bipolar tipo 1 [14, 28]. Este refinamiento algorítmico asegura que el sistema sea capaz de capturar la variabilidad estocástica de los datos reales, donde las señales de eventos raros suelen estar solapadas en el hiperespacio de características con el ruido de fondo [10, 13, 15, 31]. En consecuencia, XGBoost no solo identifica la presencia del evento minoritario, sino que garantiza una estabilidad en la identificación de falsos negativos que es hasta diez veces más robusta que en las implementaciones convencionales de *Gradient Boosting* [2, 4, 9, 11].

10.5.2. Optimización del Balance F1-Score en Datasets Altamente Imbalanceados

El equilibrio armónico entre la precisión y la exhaustividad, sintetizado en la puntuación F1, encuentra en XGBoost una plataforma de optimización excepcional gracias a su esquema de regularización estructural riguroso [1, 18, 23]. Mientras que las redes neuronales profundas tienden a sobreajustar las características de la clase mayoritaria en presencia de desequilibrios severos, XGBoost utiliza sus hiperparámetros λ y γ para suavizar los pesos de los nodos y penalizar la complejidad innecesaria del árbol, estabilizando así el compromiso predictivo en datasets con proporciones de clase extremas de hasta 42:1 [1, 9, 16, 23]. La evidencia empírica en la literatura reporta que arquitecturas híbridas y modelos de aprendizaje dual (DXGBA) logran mejoras significativas en el F1-score, superando consistentemente a SVM y redes MLP en la clasificación de quiebras financieras y diagnósticos clínicos masivos [1, 9, 10, 30].

En aplicaciones industriales de alta fidelidad, como la clasificación de formas de onda en redes eléctricas o la detección de *phishing*, XGBoost demuestra una resiliencia superior al integrar mecanismos de optimización metaheurística (SCA, PSO, BES) para la sintonización fina de sus parámetros estructurales [5, 8, 16, 18]. El uso de algoritmos como el *Bald Eagle Search* permite al modelo alcanzar precisiones del 99.7 % y F1-scores de alta estabilidad, mitigando la varianza estocástica introducida por el submuestreo de columnas y filas durante la construcción de los árboles [5, 20, 27]. Además, la capacidad de XGBoost para descomponer problemas multiclase complejos en una cascada de decisiones binarias facilita el aprendizaje de características distintivas incluso a partir de un volumen limitado de muestras minoritarias [3, 16, 32]. Esta versatilidad arquitectónica asegura que el modelo final mantenga una capacidad de generalización sólida en superficies de datos heterogéneas, consolidando a la métrica F1 como el indicador de fidelidad estándar para validar la efectividad de XGBoost en condiciones de desbalance extremo [9, 19, 29, 35].

10.5.3. Comportamiento de la Curva AUC-ROC bajo Escenarios de Ruido y Pérdida de Canales

La robustez de la curva AUC-ROC en XGBoost constituye una de sus ventajas competitivas más disruptivas en el procesamiento de bioseñales y señales industriales degradadas [11–13]. En dominios como la electroencefalografía (EEG) y el posicionamiento UWB, el algoritmo ha demostrado la capacidad de mantener un área bajo la curva superior a 0.94 e incluso alcanzar el 0.9913, aun cuando se enfrenta a una pérdida sistemática de hasta el 20 % de los canales o características de entrada [5, 11, 12]. Esta resiliencia matemática emana de su capacidad nativa para manejar datos faltantes, donde el algoritmo aprende direcciones de división predeterminadas en cada nodo para preservar la topología de la señal sin

recurrir a sesgos artificiales introducidos por métodos de imputación externa [11, 13, 15, 19]. A diferencia de los modelos basados en distancias como kNN o regresiones logísticas, que son sumamente sensibles a la fragmentación de los datos, XGBoost aprovecha la redundancia inter-canal para compensar la ausencia de información crítica, garantizando una discriminación de clases estable en condiciones de operación real [5, 7, 11, 30].

El análisis de la curva ROC bajo condiciones de ruido estocástico revela que XGBoost, potenciado por la expansión de Taylor de segundo orden, captura con precisión la curvatura de la función de pérdida, permitiendo que el sistema ignore fluctuaciones menores y se concentre en patrones de generalización sólidos [5, 6, 10, 21]. Estudios comparativos indican que XGBoost supera a Random Forest en margen de confianza, proporcionando una probabilidad de clasificación correcta significativamente más alta —hasta un 46.3% superior— en hiper-superficies multivariadas complejas [8, 13, 29, 35]. La estabilidad de la métrica AUC se mantiene constante a través de diferentes estrategias de validación cruzada —de 3 pliegues a 10 pliegues—, validando la invariancia del modelo ante particiones de datos heterogéneas y señales con alta variabilidad temporal [11, 18, 20, 25]. Finalmente, en la detección de ataques DDoS en redes SDN, XGBoost reporta tasas de falsos positivos cercanas a cero (0.0003%), lo que se traduce en una curva ROC de ascenso casi vertical que define el estado del arte en eficiencia de clasificación para sistemas de alta disponibilidad [4, 7, 34].

10.5.4. Métricas de Ganancia y Cobertura en la Interpretación Estructural del Modelo

La interpretabilidad de alta fidelidad en XGBoost se articula a través de las métricas de Ganancia (*Gain*) y Cobertura (*Cover*), las cuales proporcionan una auditoría cuantitativa sobre la importancia de las características en la reducción del riesgo estructural [11, 15, 22]. La Ganancia representa la mejora promedio en el ajuste del modelo aportada por cada división basada en una característica específica, derivada directamente de los estadísticos de primer orden (gradientes) y segundo orden (hessianos) [6, 11, 15, 22]. En aplicaciones de espectroscopía LIBS y análisis hiperespectral (HSI), esta métrica permite identificar un subconjunto crítico de variables —como las líneas características del cobre— que pueden representar hasta el 98.97% de la importancia acumulada, facilitando una reducción de dimensionalidad justificada científicamente que elimina la redundancia espectral sin comprometer la precisión [15, 16, 22]. Por otro lado, la Cobertura cuantifica el número relativo de observaciones influenciadas por un atributo en el ensamble, ofreciendo una perspectiva sobre la estabilidad y relevancia global de cada descriptor en la topología de los árboles [3, 5, 22, 31].

El uso sinérgico de *Gain* y *Cover* permite trascender la naturaleza de caja negra.^a asociada tradicionalmente a los modelos de ensamble, integrándose con frameworks de explicabilidad como SHAP (*SHapley Additive exPlanations*) para validar la causalidad en sistemas de misión crítica [3, 5, 8, 11]. Esta transparencia estructural es fundamental en el diagnóstico médico y la ciberseguridad, donde la identificación de las características dominantes —como el *IP reputation score* o canales EEG específicos— permite a los analistas verificar la lógica de decisión frente a evidencias neurofisiológicas o comportamentales [5, 9, 11, 30]. Además, la implementación de la computación granular multi-distancia integrada con XGBoost (GXGBoost) ha demostrado que las interacciones entre características, capturadas mediante la ganancia de división, revelan estructuras internas no lineales que el análisis de componentes principales (PCA) convencional a menudo ignora [19, 31–33]. En conclusión, las métricas de importancia estructural de XGBoost no solo optimizan el rendimiento computacional al permitir la eliminación de ruido, sino que dotan al ingeniero de aprendizaje estadístico de una herramienta analítica para la toma de decisiones basada en evidencia cuantitativa [10, 15, 17, 18, 22].

10.6. Conclusiones

La viabilidad técnica de XGBoost frente a las arquitecturas de aprendizaje profundo se consolida a través de un equilibrio de alto rendimiento entre la celeridad de procesamiento y la fidelidad predictiva en entornos industriales de alta exigencia. La evidencia empírica reportada en la literatura científica demuestra que este algoritmo alcanza velocidades de instrucción hasta 109 veces superiores a redes recurrentes tipo LSTM y 19 veces superiores a modelos convolucionales, operando exclusivamente bajo recursos de CPU y eliminando la dependencia obligatoria de infraestructuras de aceleración por GPU [9, 16]. Esta

eficiencia operativa no compromete la integridad del sistema ante la presencia de ruido estocástico o la fragmentación de las señales, ya que su arquitectura de ramificación aditiva permite una gestión nativa de datos faltantes mediante el aprendizaje de direcciones de división predeterminadas, preservando la topología de la información sin recurrir a sesgos de imputación externa [11, 12]. En escenarios caracterizados por la escasez de muestras, donde las redes neuronales sufren de inestabilidad o sobreajuste, XGBoost extrae representaciones de alta dimensionalidad con una robustez estructural superior, garantizando una convergencia estocástica precisa incluso en hiper-superficies multivariadas caracterizadas por una alta variabilidad temporal y señales degradadas [4–6, 31].

El impacto estratégico de la personalización analítica mediante funciones de pérdida adaptativas posiciona a XGBoost como la solución de referencia para la resolución de desbalances severos de clases en sistemas de misión crítica. La integración de la pérdida focal y de variantes sinérgicas permite al optimizador de segundo orden concentrar el aprendizaje en las instancias de difícil clasificación, mitigando el sesgo hacia las categorías mayoritarias y elevando significativamente la sensibilidad en la detección de eventos raros en dominios de ciberseguridad y diagnóstico médico [4, 6, 14, 23]. Esta solidez se ve potenciada por un marco de regularización estructural riguroso que, mediante el control de los hiperparámetros γ y λ , penaliza la complejidad innecesaria y suaviza los pesos de los nodos para asegurar una generalización consistente en datos heterogéneos [1, 2, 10, 15]. La superioridad algorítmica demostrada responde a la capacidad del sistema para integrar información de la curvatura de la pérdida a través de estadísticos hessianos, facilitando una optimización cuadrática exacta que supera las limitaciones de fidelidad de los modelos lineales y los árboles de decisión convencionales [7, 13, 18, 20]. En conclusión, la versatilidad para ajustarse a distribuciones de datos no-IID y su transparencia mediante métricas de ganancia consolidan a XGBoost como el estándar de oro en la ingeniería de clasificación contemporánea [3, 5, 22, 32].

Referencias

- [1] R. Alwanin, O. Bchir, and M. M. B. Ismail, "Gradient boosting-based simultaneous classification and regression approach," *IEEE Access*, vol. 13, pp. 98 557–98 573, 6 2025. [Online]. Available: <https://ieeexplore.ieee.org/document/11024011/>
- [2] C. Du, "Construction of consumption data optimization model based on xgboost algorithm," *Procedia Computer Science*, vol. 262, pp. 278–286, 2025. [Online]. Available: <https://linkinghub.elsevier.com/retrieve/pii/S1877050925019015>
- [3] R. G. Pensa, A. Crombach, S. Peignier, and C. Rigotti, "Explaining random forest and xgboost with shallow decision trees by co-clustering feature importance," *Machine Learning*, vol. 114, p. 287, 12 2025. [Online]. Available: <https://link.springer.com/10.1007/s10994-025-06932-9>
- [4] M. Abdelhaq, S. Palanisamy, M. Gopinath, V. G. S. Manasa, M. A. Ram, and S. K. MD, "A hybrid xgboost-svm ensemble framework for robust cyber-attack detection in the internet of medical things (iomt)," *Scientific Reports*, vol. 16, p. 6855, 1 2026. [Online]. Available: <https://www.nature.com/articles/s41598-026-37832-0>
- [5] S. Kundu, R. P. Chaturvedi, A. Mishra, A. Agrawal, S. M. Aldossary, M. Ayadi, K. B. Adem, and A. Hashmi, "A trustworthy cybersecurity model for transparent cyberattack detection using bald eagle search tuned xgboost and explainable ai," *Journal of Cloud Computing*, vol. 15, p. 58, 3 2026. [Online]. Available: <https://link.springer.com/10.1186/s13677-026-00878-6>
- [6] J. Tian, P.-W. Tsai, K. Zhang, X. Cai, H. Xiao, K. Yu, W. Zhao, and J. Chen, "Synergetic focal loss for imbalanced classification in federated xgboost," *IEEE Transactions on Artificial Intelligence*, vol. 5, pp. 647–660, 2 2024, cited by: 21. [Online]. Available: <https://ieeexplore.ieee.org/document/10063985/>
- [7] H. A. Alamri and V. Thayananthan, "Bandwidth control mechanism and extreme gradient boosting algorithm for protecting software-defined networks against ddos attacks," *IEEE Access*, vol. 8, pp. 194 269–194 288, 10 2020. [Online]. Available: <https://ieeexplore.ieee.org/document/9239958/>
- [8] M. A. Budiman and J. Manurung, "Enhancing xgboost performance for classification tasks using particle swarm optimization and shap-based model interpretability," *International Journal of Basic and Applied Science*, vol. 14, pp. 162 – 174, 2026, cited by: 0. [Online]. Available: <https://www.scopus.com/pages/publications/105034763804?origin=resultslist>
- [9] Z. Rais, S. M. Fahmuddin, Saida, and A. T. Utomo, "Implementation of machine learning algorithm with extreme gradient boosting (xgboost) method in hypertension level classification," *Journal of Applied Science, Engineering, Technology, and Education*, vol. 7, pp. 126 – 136, 4 2025, cited by: 2; All Open Access; Gold Open Access. [Online]. Available: <https://www.scopus.com/pages/publications/105013094963?origin=resultslist>
- [10] Q. Su, L. Chen, and L. Qian, "Optimization of big data analysis resources supported by xgboost algorithm: Comprehensive analysis of industry 5.0 and esg performance," *Measurement: Sensors*, vol. 36, p. 101310, 12 2024. [Online]. Available: <https://linkinghub.elsevier.com/retrieve/pii/S2665917424002861>
- [11] H. Dabool, Z. Aghbari, N. Ahmed, I. Afyouni, H. Alashwal, and S. Khanday, "A reliable and explainable eeg-based eye state classification via xgboost with missing data resilience and shap-lime explanations," *Biomedical Signal Processing and Control*, vol. 120, p. 110161, 7 2026, cited by: 0. [Online]. Available: <https://linkinghub.elsevier.com/retrieve/pii/S1746809426007159>

- [12] S. Wang and N. S. Ahmad, "Robust classification of uwb nlos/los using combined fce and xgboost algorithms," *IEEE Access*, vol. 12, pp. 151 030–151 045, 10 2024. [Online]. Available: <https://ieeexplore.ieee.org/document/10716641/>
- [13] F. Sun, R. Wang, B. Wan, Y. Su, Q. Guo, Y. Huang, and X. Wu, "Efficiency of extreme gradient boosting for imbalanced land cover classification using an extended margin and disagreement performance," *ISPRS International Journal of Geo-Information*, vol. 8, p. 315, 7 2019, cited by: 9; All Open Access; Gold Open Access; Green Open Access. [Online]. Available: <https://www.mdpi.com/2220-9964/8/7/315>
- [14] R. Manmadhan and N. B. S, "Enhancing bipolar disorder diagnosis with custom loss xgboost for imbalanced multi-class classification," in *2025 11th International Conference on Smart Computing and Communications (ICSCC)*. IEEE, 7 2025, pp. 1–5, cited by: 1. [Online]. Available: <https://ieeexplore.ieee.org/document/11233652/>
- [15] A. Yasen, Y. Zhou, W. Gao, Z. Zhang, R. Tudi, M. Xiang, and B. Abulimiti, "A ma-ssa-optimized xgboost-mlp framework using libs for rapid classification and quantitative analysis of heavy metals in traditional chinese medicines," *Journal of Pharmaceutical and Biomedical Analysis*, vol. 270, p. 117296, 3 2026, cited by: 1. [Online]. Available: <https://linkinghub.elsevier.com/retrieve/pii/S0731708525006375>
- [16] H. Li, Y. Zhao, W. Tan, H. Wang, J. Li, and T. Lei, "Research on power frequency waveform classification for transmission lines based on a cascaded xgboost model," in *2025 6th International Conference on Smart Grid and Energy Engineering (SGEE)*. IEEE, 11 2025, pp. 73–79, cited by: 0. [Online]. Available: <https://ieeexplore.ieee.org/document/11385589/>
- [17] J. Frnda, J. Rozhon, M. Uhrina, J. Bienik, and M. Voznak, "Video quality prediction and classification using xgboost under variable encoding and network conditions," *Scientific Reports*, vol. 16, p. 16614, 4 2026. [Online]. Available: <https://www.nature.com/articles/s41598-026-47932-6>
- [18] M. Bukumira, M. Zivkovic, M. Antonijevic, L. Jovanovic, N. Bacanin, and T. Zivkovic, "The extreme gradient boosting method optimized by hybridized sine cosine metaheuristics for ship vessel classification," in *Lecture Notes in Networks and Systems*, vol. 891. Springer Nature Singapore, 2 2024, pp. 255–270, cited by: 10. [Online]. Available: https://link.springer.com/10.1007/978-981-99-9524-0_20
- [19] W. Su, F. Jiang, C. Shi, D. Wu, L. Liu, S. Li, Y. Yuan, and J. Shi, "An xgboost-based knowledge tracing model," *International Journal of Computational Intelligence Systems*, vol. 16, p. 13, 2 2023. [Online]. Available: <https://link.springer.com/10.1007/s44196-023-00192-y>
- [20] O. Almomani, B. Venkatesh, S. P. Chaudhary, A. Mishra, S. Sujai, S. Juneja, P. Pradhan, S. P. Venkatesan, A. Bhowmik, and Y. Tamene, "Intelligent tool wear monitoring using xgboost, svr, and dnn models in nmql environment," *Scientific Reports*, vol. 16, p. 10030, 2 2026. [Online]. Available: <https://www.nature.com/articles/s41598-026-40968-8>
- [21] C. Shen, L. Xiang, and W. Wang, "Valuation of science and technology innovation enterprises based on xgboost-ga-bp neural network model," *Scientific Reports*, vol. 15, p. 31427, 8 2025. [Online]. Available: <https://www.nature.com/articles/s41598-025-15282-4>
- [22] X. Shang, C. Cui, X. Sun, X. Wang, and J. Zhang, "Classification task-driven hyperspectral band selection via interpretability from xgboost," *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, vol. 18, pp. 13 733–13 754, 5 2025. [Online]. Available: <https://ieeexplore.ieee.org/document/11008687/>
- [23] C. Wang, C. Deng, and S. Wang, "Imbalance-xgboost: leveraging weighted and focal losses for binary label-imbalanced classification with xgboost," *Pattern Recognition Letters*, vol. 136, pp. 190 – 197, 5 2020, cited by: 263; All Open Access; Green Open Access. [Online]. Available: <https://www.scopus.com/pages/publications/85086585292?origin=resultslist>
- [24] C. Leo. (2026) The math behind XGBoost. Accedido el 2 de junio de 2026. [Online]. Available: <https://medium.com/@cristianleo120/the-math-behind-xgboost-3068c78aad9d>
- [25] H. Joe and H.-G. Kim, "Multi-label classification with xgboost for metabolic pathway prediction," *BMC Bioinformatics*, vol. 25, p. 52, 2 2024. [Online]. Available: <https://bmcbioinformatics.biomedcentral.com/articles/10.1186/s12859-024-05666-0>

- [26] XGBoost Developers. (2026) XGBoost tutorials: Introduction to model tuning and additive learning. Accedido el 2 de junio de 2026. [Online]. Available: <https://xgboost.readthedocs.io/en/stable/tutorials/model.html>
- [27] A. Ali, Z. Haider, H. Shahbaz, H. Masood, B. Gul, A. Rashid, Z. Waheed, J. Ha, C. Kim, M. Syafrudin, and N. L. Fitriyani, “Retracted article: Towards improved fake news detection using a hybrid roberta and metadata enhanced xgboost model,” *Scientific Reports*, vol. 16, p. 1967, 12 2025. [Online]. Available: <https://www.nature.com/articles/s41598-025-29942-y>
- [28] D. P. Prabha and C. V. Priscilla, “Probabilistic xgboost threshold classification with autoencoder for credit card fraud detection,” *International Journal on Recent and Innovation Trends in Computing and Communication*, vol. 11, pp. 528–537, 8 2023, cited by: 7; All Open Access; Gold Open Access. [Online]. Available: <https://ijritcc.org/index.php/ijritcc/article/view/7234>
- [29] S. S. Betgeri, M. Shukla, D. Kumar, S. B. Khan, M. A. Khan, and N. A. Alkhaldi, “Enhancing seizure detection with hybrid xgboost and recurrent neural networks,” *Neuroscience Informatics*, vol. 5, 6 2025.
- [30] A. Hassoon, F. E. M. Ghazali, and T. A. Khaleel, “Application of xgboost and artificial neural networks in predicting housing project productivity,” *Discover Artificial Intelligence*, 12 2025.
- [31] K. T. Chui, S. K. S. Cheung, J. Liu, and K. K. Ng, “Proceedings of the 2024 international conference on wireless communications, networking and applications,” in *Proceedings of the 2024 International Conference on Wireless Communications, Networking and Applications*, P. Siarry, S. K. S. Cheung, M. A. Jabbar, and X. Li, Eds., vol. 1550. Springer Nature Singapore, 12 2026, pp. 64–73. [Online]. Available: <https://link.springer.com/10.1007/978-981-95-6946-5>
- [32] B. Lan, Y. Chen, and K. Wu, “A granular xgboost classification algorithm,” *Applied Intelligence*, vol. 55, p. 895, 8 2025, cited by: 6. [Online]. Available: <https://link.springer.com/10.1007/s10489-025-06762-1>
- [33] W. Liu, X. Zhang, J. Zhang, N. Li, L. Ren, and Z. Liu, “An efficient iot device classification method based on the integration of variational autoencoder and xgboost,” in *Proceedings of the 2025 9th International Conference on High Performance Compilation, Computing and Communications*. ACM, 8 2025, pp. 159–164, cited by: 0; All Open Access; Gold Open Access. [Online]. Available: <https://dl.acm.org/doi/10.1145/3774949.3774975>
- [34] A. Vagenas, D. Garyfallou, N. Evmorfopoulos, and G. Stamoulis, “Timeboost: Accelerating timing analysis engines using xgboost,” *AEU - International Journal of Electronics and Communications*, vol. 200, p. 155870, 10 2025. [Online]. Available: <https://linkinghub.elsevier.com/retrieve/pii/S1434841125002110>
- [35] B. Kapoor and B. Nagpal, “Gradient boosting for predicting the relation between bio-medical signals and seizures using lgbm and xgboost,” *Journal of Mobile Multimedia*, vol. 20, pp. 359–390, 6 2024, DOI: 10.13052/jmm1550-4646.2025.